Universidad Nacional del Centro de la Provincia de Buenos Aires

30 de Junio, 2026

DETECCIÓN AUTOMÁTICA DE CAÍDAS: EVALUACIÓN EXPERIMENTAL DE ENFOQUES VISUALES BASADOS EN ESTIMADORES DE POSE Y MODELOS DE REDES NEURONALES

Alumnos: Gianni Hernán Sottile, Giorgio Iván Loguercio
Directora: Prof. Dr. Virginia Yannibelli

Agenda

01 Agenda

02 Introducción

03 Relevamiento Bibliografico

04 Limitaciones en la literatura

05 Nuestro trabajo

06 Datasets utilizados

07 Estimadores de pose utilizados

08 Proceso de detección de una caída

09 Enfoques

10 Metodologías de evaluación y validación

11 Métricas de evaluación

12 Experimentos

13 Conclusión

14 Trabajo a futuro

Introducción

Las caídas en adultos mayores representan una problemática crítica en la salud, ya que pueden causar graves lesiones físicas y psicológicas.

Según la Organización Mundial de la Salud (OMS), la población mundial envejece a un ritmo acelerado: en 2030, una de cada seis personas tendrá 60 años o más, y se prevé que este grupo se duplique para 2050, alcanzando los 2100 millones. A medida que la edad avanza, aumenta la frecuencia de caídas, y sus consecuencias suelen implicar **pérdida de independencia** y **deterioro en la calidad de vida** de las personas. Otro problema frecuente es la imposibilidad de que las personas se levanten tras sufrir una caída, especialmente en quienes viven solos, lo que puede derivar en **lesiones severas**.

En este contexto, la detección automática de caídas en tiempo real cumple un rol esencial para **brindar asistencia** oportuna y mitigar estos riesgos, contribuyendo a que las personas mayores vivan de forma más segura y autónoma.

Relevamiento bibliógrafico

Tipos de enfoques



Enfoques basados en el uso de sensores

Requieren que las personas porten dispositivos para poder recopilar datos. Estos sensores están embebidos en smartphones o smartwatches, y facilitan la obtención de datos sin necesidad de más equipamiento.

Ventajas :

- Protección de la privacidad de los usuarios.

Desventajas :

- Poco adecuado para un monitoreo continuo y a largo plazo en el entorno de los adultos mayores.
- Necesidad de calibración manual frecuente y corta duración de bateria
- Requerimiento de que el usuario lleve el dispositivo de forma constante (posibilidad de incumplimiento)



Enfoques visuales

Basados en el análisis de imágenes obtenidas mediante cámaras instaladas en el ambiente para detectar las caídas.

Ventajas :

- Fácil incorporación y escalabilidad (incremento en el uso de cámaras en los últimos años)
- Elimina la posibilidad de incumplimiento
- Alternativa no intrusiva
- Adecuado para monitoreo continuo y a largo plazo

Desventajas :

- Captura de imágenes de los usuarios (privacidad)

Relevamiento bibliógrafico

Enfoques visuales



En los últimos años, se ha enfatizado el desarrollo de enfoques visuales basados en la utilización de modelos de redes neuronales:

- **Modelos CNN** : redes neuronales profundas diseñadas específicamente para el análisis de información visual, procesando una imagen como entrada, y clasificandola como caída o no caída.
- **Modelo RNN** : procesan la información de forma secuencial, añadiendo el factor temporal, y complementando a los modelos CNN.
- **Modelo LSTM** : variante avanzada de los modelos RNN que captura dependencias temporales a largo plazo.
- **Modelos de Transformers** : ayudan a mejorar aún más la captura de dependencias a largo plazo, y la comprensión contextual en la secuencia de imágenes que conforman al video. Se utilizan de manera invidivual o conjunta con CNN.

Relevamiento bibliógrafico

Estimación de pose



Una gran parte de los enfoques visuales mencionados previamente utilizan un estimador de pose en forma previa al modelo de red neuronal utilizado.
Un estimador de pose es un modelo de inteligencia artificial que toma como entrada una imagen en la que aparece una persona y, genera como salida las coordenadas de los principales puntos de articulación del cuerpo de esa persona que conforman a su pose. Luego, los enfoques usan esas poses como entrada para el modelo de red neuronal determinando la ocurrencia de una caída en base al análisis de las coordenadas de los puntos de articulación, en lugar de hacerlo en base al análisis de los píxeles de la imagen original completa.

Ventajas :

- El análisis realizado por el modelo de red neuronal no se ve afectado por el ruido en la imagen
- Requiere mucho menos tiempo que el análisis basado en los píxeles de la imagen completa.
- El modelo de red neuronal no recibe datos que comprometan la privacidad de la persona en la imagen (por ejemplo imagen del rostro de esa persona)

Limitaciones en la evaluación comparativa de enfoques visuales

En relación al desempeño logrado por los enfoques visuales relevados en la literatura, en cuanto a su efectividad y eficiencia para la detección de caídas, es necesario señalar que la mayoría de estos enfoques han sido evaluados en relación a distintos estimadores de pose y distintos *datasets* de imágenes de video.

La literatura carece de estudios que ofrezcan una evaluación comparativa de enfoques visuales en relación a estimadores de pose y *datasets* de imágenes de video considerados de relevancia.

La disponibilidad de este tipo de estudios podría ser de utilidad para aquellos ingenieros de software que deban decidir sobre el enfoque visual a utilizar en el desarrollo de un sistema de detección automática de caídas.

Nuestro trabajo

El trabajo consiste en una evaluación comparativa de enfoques visuales para la detección automática de caídas. En esta evaluación, se consideraron enfoques visuales recientemente propuestos en la literatura, que se basan en distintos modelos de redes neuronales y estimadores de pose, y que son representativos de los enfoques existentes en el estado del arte.

- Un enfoque A que usa los estimadores de pose **AlphaPose** y **OpenPose** con una arquitectura híbrida compuesta por una **CNN** y una **LSTM**
- Un enfoque B que usa el estimador de pose **YOLOv8-pose** y una arquitectura híbrida compuesta de una **TCN** (temporal convolutional network) y un **TE** (transformer encoder).
- Un enfoque C que usa el estimador de pose **YOLOv8-pose** con un **TE**.

Además, se consideraron variantes de estos enfoques definidas con el propósito de abordar distintas limitaciones de los mismos.
Se realizó una evaluación comparativa de estos enfoques y variantes en relación a distintos *datasets* relevantes en la literatura: **UP-Fall**, **UR-Fall**, **Le2i**, **GMDCSA-24**; y en relación a distintos estimadores de pose que son usualmente utilizados en este área: **AlphaPose**, **OpenPose**, **YOLOv8-pose**, **MediaPipe**; los cuales conformaran las **duplas (dataset, estimador)**. El desempeño de estos enfoques y variantes ha sido medido en términos de las métricas utilizadas usualmente en la literatura para la evaluación de enfoques basados en modelos de redes neuronales, y al tiempo de cómputo requerido para su entrenamiento y para la clasificación en tiempo real, para cada dupla.

Datasets utilizados

Se consideraron los *datasets* **UP-Fall**, **UR-Fall**, **Le2i** y **GMDCSA-24**, dado que son los más utilizados en la literatura reciente sobre enfoques visuales para la detección automática de caídas. Todos estos datasets compuestos por videos de AVD (actividades de la vida diaria) y caídas, los cuales son simulaciones realizadas por actores.

UP-Fall

El *dataset* contiene en total **1122 videos**, incluyendo 612 videos en los que se simulan AVD y 510 videos en los que se simulan caídas. En relación a las personas que participaron de estos videos, se consideraron 17 personas jóvenes saludables de entre 18 y 24 años. Los videos se filmaron desde dos cámaras (vista lateral y una vista frontal) a **18 fps** (imágenes por segundo) a una **resolución de 640x480** píxeles.

UR-Fall

El *dataset* contiene en total **100 videos**, incluyendo 40 videos en los que se simulan AVD y 60 videos en los que se simulan caídas. Las simulaciones de caídas fueron registradas simultáneamente por dos cámaras, mientras que las AVDs por una sola. Las grabaciones de estos videos se realizaron con una **resolución de 640x480** y a **30 fps**. Además, el ambiente de grabación de estos videos tenía un desafío realista, ya que la iluminación no era controlada, sino que variaba naturalmente según el momento del día.

Le2i

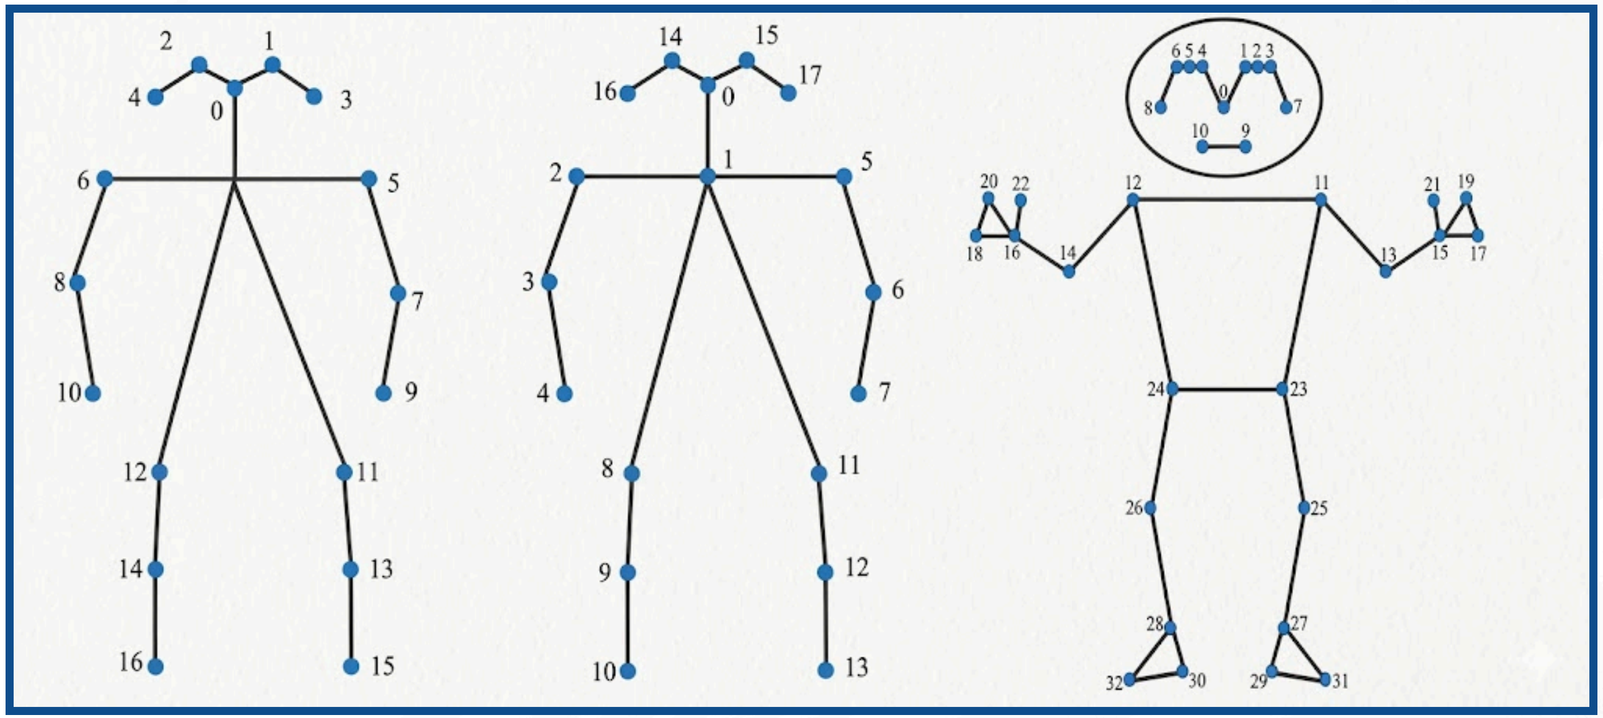
El *dataset* contiene en total **222 videos**, incluyendo 79 videos en los que se simulan AVD y 143 videos en los que se simulan caídas Estos fueron capturados con una **resolución de 320x240** píxeles a **25 fps**.
Los videos fueron capturados en distintos ambientes con desafíos como iluminación variable, sombras y reflejos que pueden ser detectados como objetos en movimiento, y dificultades típicas como oclusiones o fondos desordenados y texturizados. Además, las simulaciones se realizaron en distintas direcciones, sin tener en cuenta el punto de vista de la cámara.

GMDCSA-24

El *dataset* contiene en total **160 videos**, incluyendo 81 videos en los que se simulan AVDs y 79 videos en los que se simulan caídas. Además, los videos de estas simulaciones fueron capturados con una **resolución de 1280x720** píxeles a **30 fps**, y se grabaron a diferentes horas del día, con niveles de iluminación variables.

Estimadores de pose utilizados

Se consideraron los estimadores de pose **AlphaPose**, **OpenPose**, **YOLOv8-pose** y **MediaPipe**. Estos estimadores difieren en cuanto a la cantidad de puntos de articulación que pueden identificar. En concreto, **AlphaPose** y **YOLOv8-pose** identifican 17 puntos, **OpenPose** identifica 19 puntos y **MediaPipe** identifica 33 puntos.

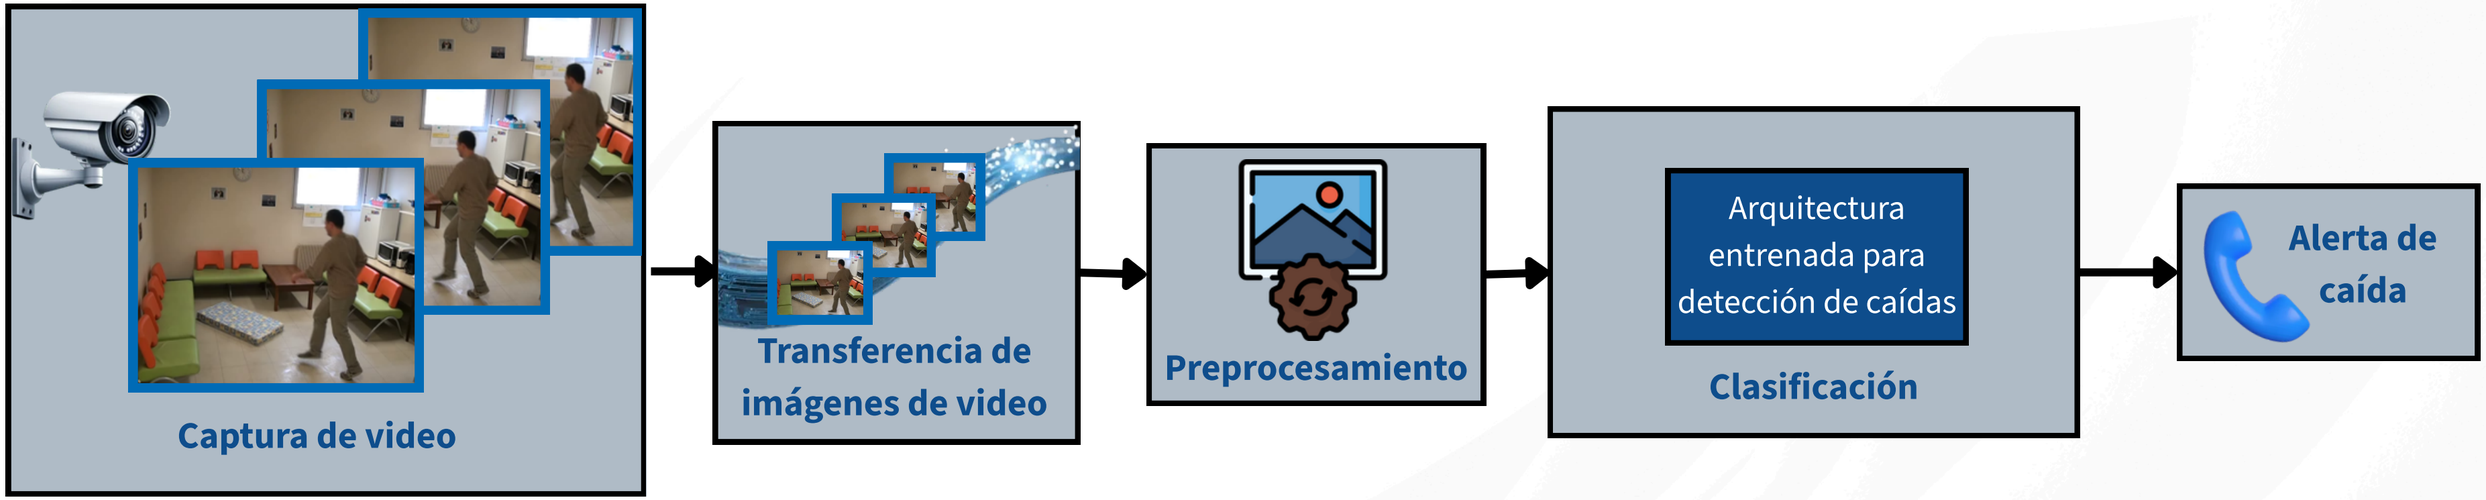


YOLOv8-pose
AlphaPose

OpenPose

MediaPipe

Proceso de detección de una caída



El proceso de detección automática de caídas en tiempo real está compuesto por las siguientes etapas:

Captura de video: se recolectan imágenes secuenciales de un ambiente, mediante una cámara instalada en el mismo.

Transferencia de imágenes de video: se envían las imágenes secuenciales recolectadas al dispositivo que se encarga de realizar la detección automática de las caídas, priorizando la minimización del tiempo de transferencia de las imágenes.

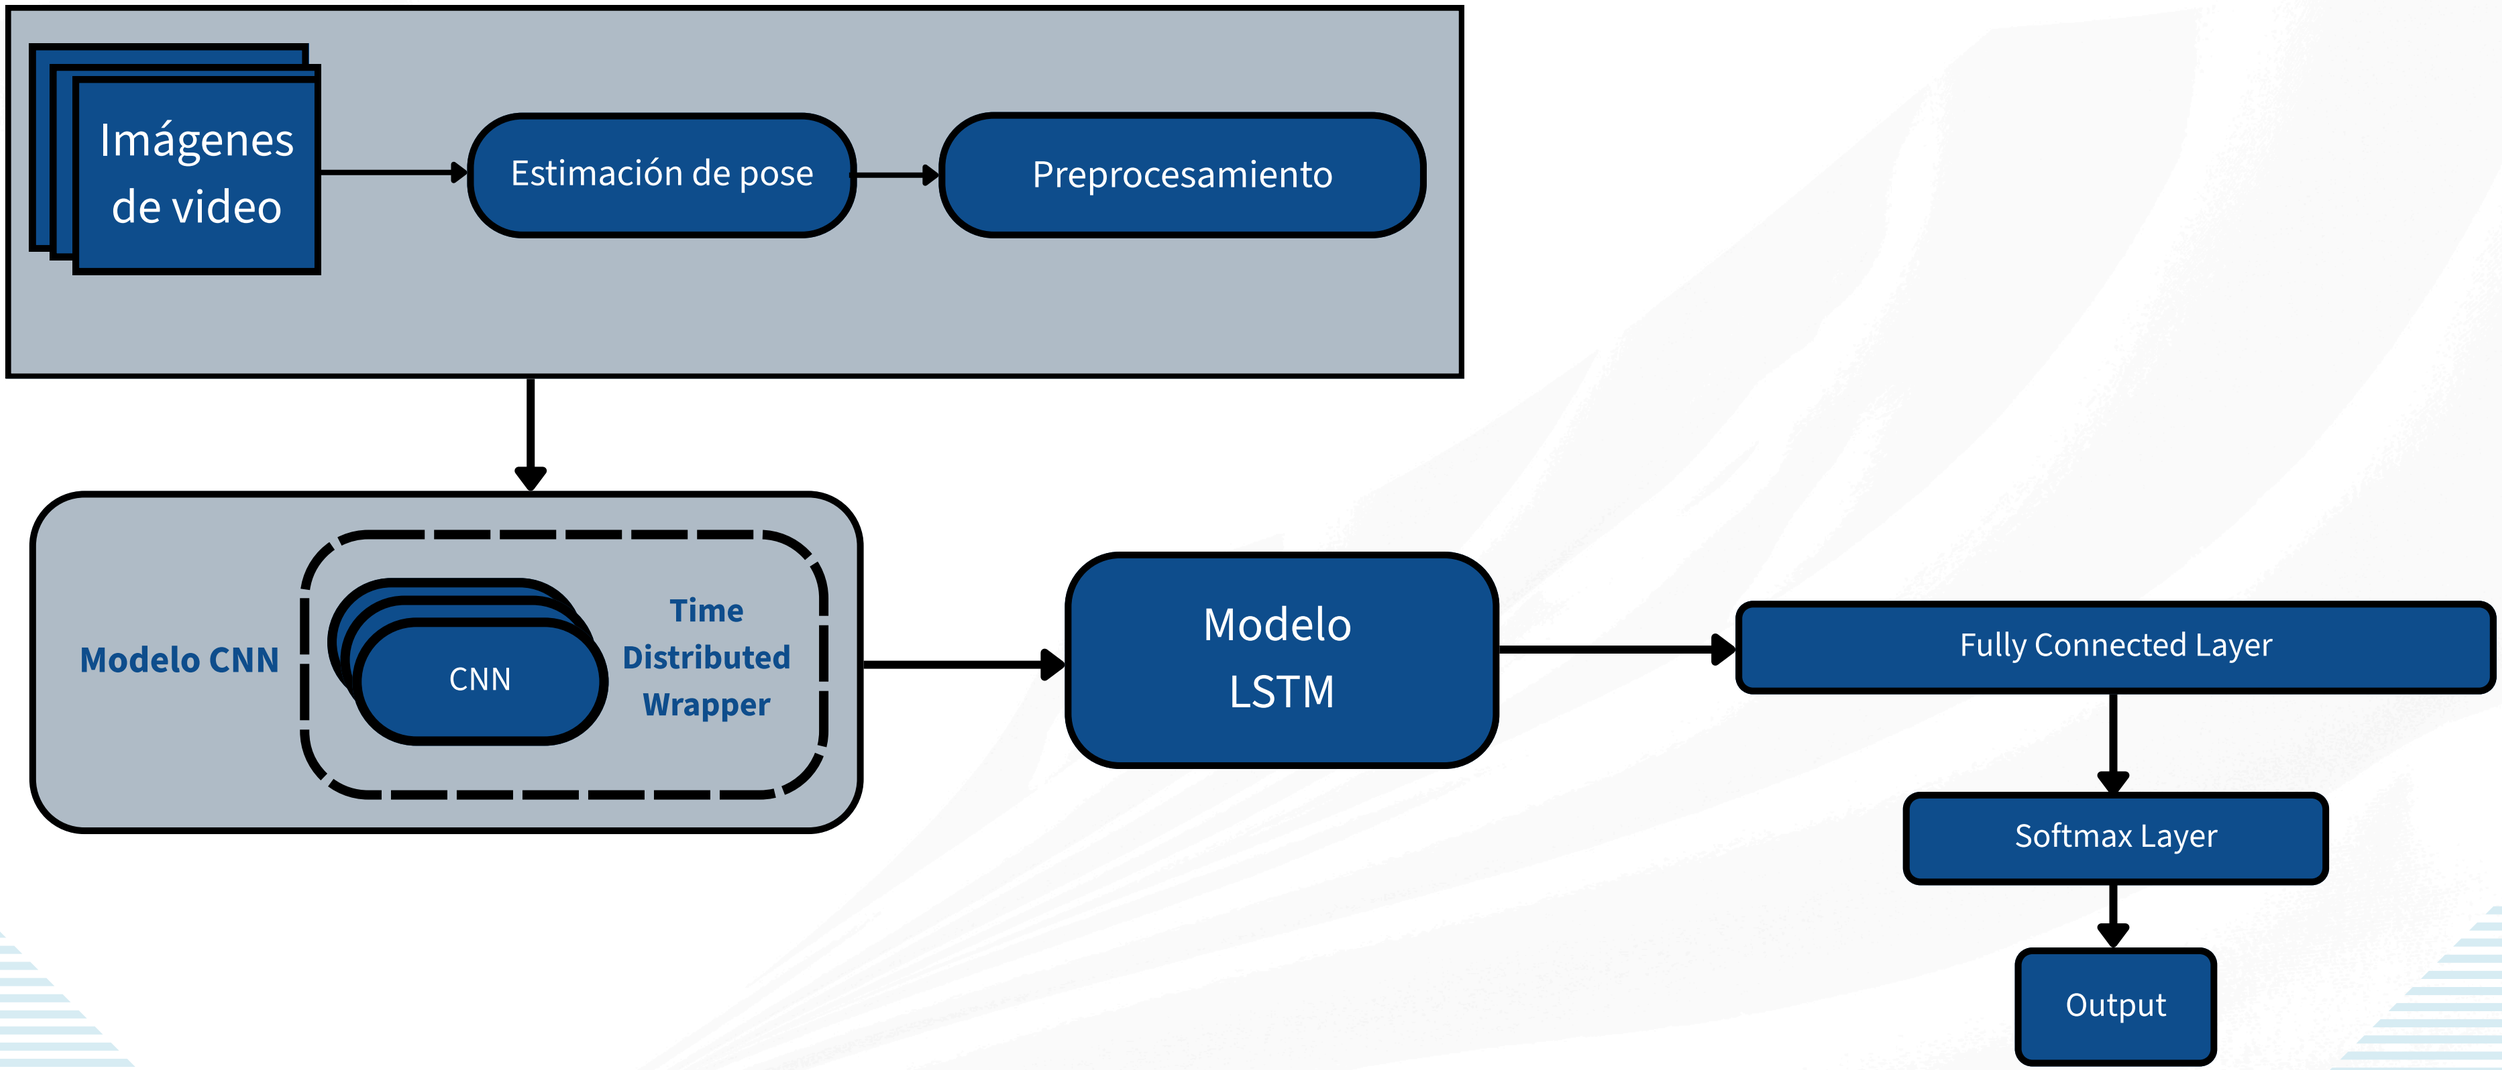
Preprocesamiento : procesamiento de las imágenes recibidas para obtener la entrada requerida por la arquitectura.

Clasificación : proceso en el cual la arquitectura toma la entrada preprocesada y la clasifica como caída o AVD.

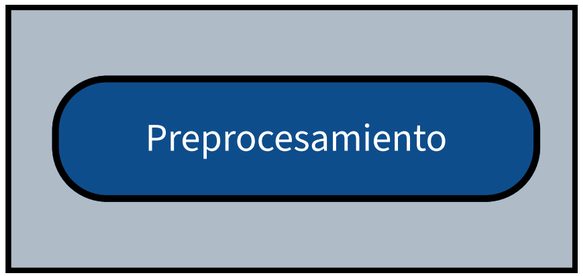
Alerta de caída: se notifica sobre la ocurrencia de una caída a los individuos o entidades que correspondan (por ejemplo, servicios de emergencia, cuidadores o familiares de la persona afectada).

Enfoque A

Este enfoque corresponde al propuesto por Inturi et al. el cual utiliza un estimador de pose (**AlphaPose/OpenPose**) para estimar las poses, y luego una arquitectura híbrida **TD-CNN-LSTM** para determinar la ocurrencia de caídas.



Preprocesamiento



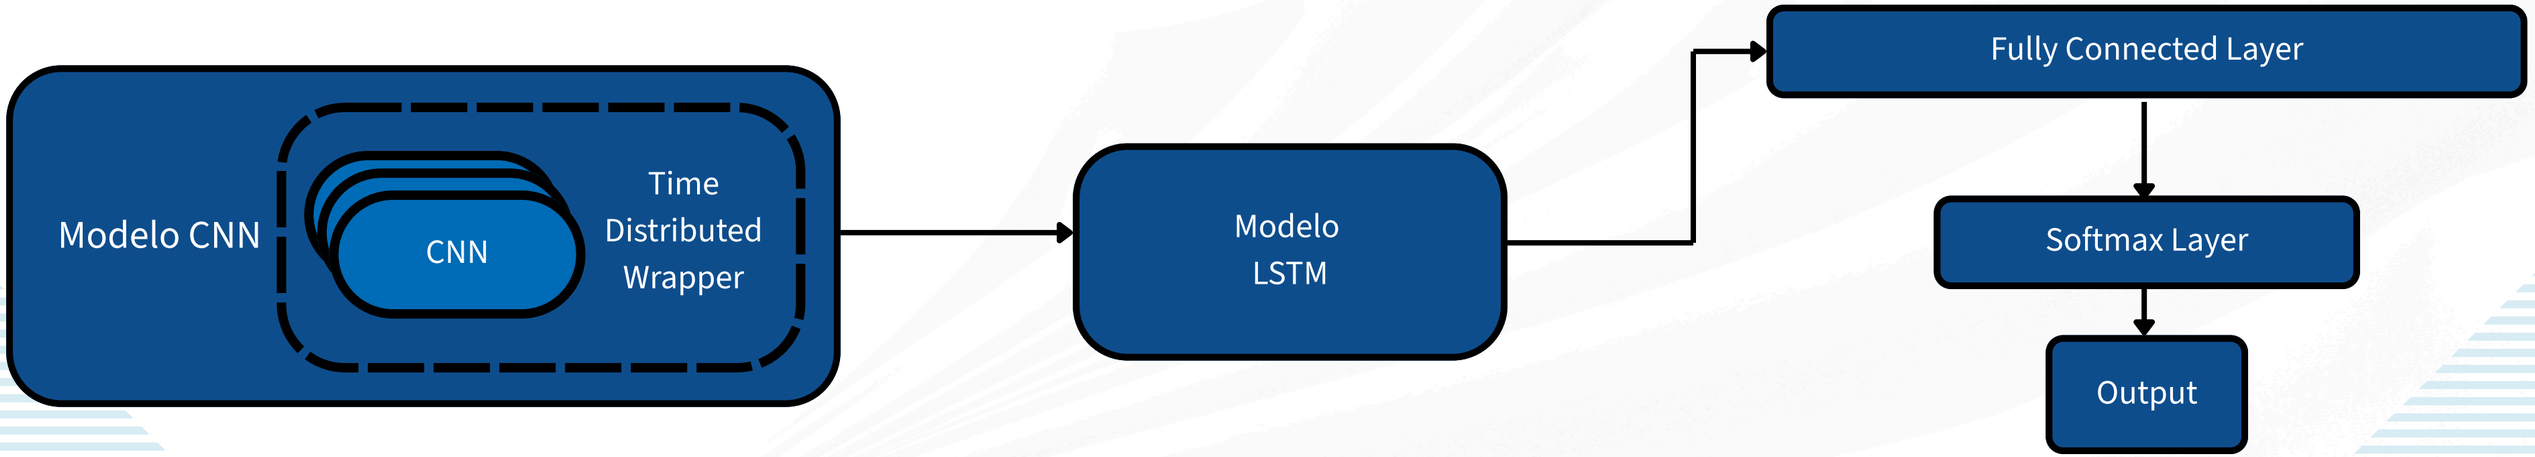
- Cargar en memoria las poses estimadas previamente
- Política de selección de la pose de la persona protagonista
- Normalización de poses para ajustar coordenadas a una escala común
- Creación y etiquetado de ventanas deslizantes(tamaño de 64 poses y solapamiento de 48 poses)
- Codificación de las etiquetas de las ventanas de pose (*One-Hot Encoding*)
- Particionamiento de las ventanas de pose según la metodología utilizada

Arquitectura del Enfoque A

Etapa CNN: Se utiliza un **TD** (Time-Distributed) Wrapper que se encarga de aplicar un modelo **CNN** a cada una de las 64 poses de la ventana. Este modelo extrae las características espaciales de una pose dada. Luego, se define una secuencia de 64 vectores, donde los vectores contienen las características espaciales de las poses de la ventana. Esta secuencia es utilizada como entrada para la etapa posterior.

Etapa LSTM: Se aplica un modelo **LSTM** sobre la secuencia de vectores de características espaciales obtenida de la etapa anterior, con el fin de identificar las dependencias a largo plazo de la secuencia de poses que lleva a una caída. Este modelo genera un único vector de características que condensa la evolución temporal de la ventana de 64 poses recibida como entrada por la arquitectura. Este vector es usado como entrada para la siguiente etapa.

Etapa de clasificación: Se aplica una fully connected layer , que analiza las relaciones no lineales entre las características. Estas relaciones se utilizan como entrada para una Softmax layer, la cual es una fully connected layer con función de activación Softmax que genera la salida de esta etapa. Esta salida consiste en la probabilidad de que la ventana de 64 poses recibida como entrada por la arquitectura corresponda a una caída.



Variantes del Enfoque A

Con el objetivo de enriquecer los *datasets* de imágenes de video, y abordar el desbalance de clases (etiquetas) inherente a estos datasets, se definieron tres variantes del enfoque previamente descrito, las cuales son presentadas a continuación.

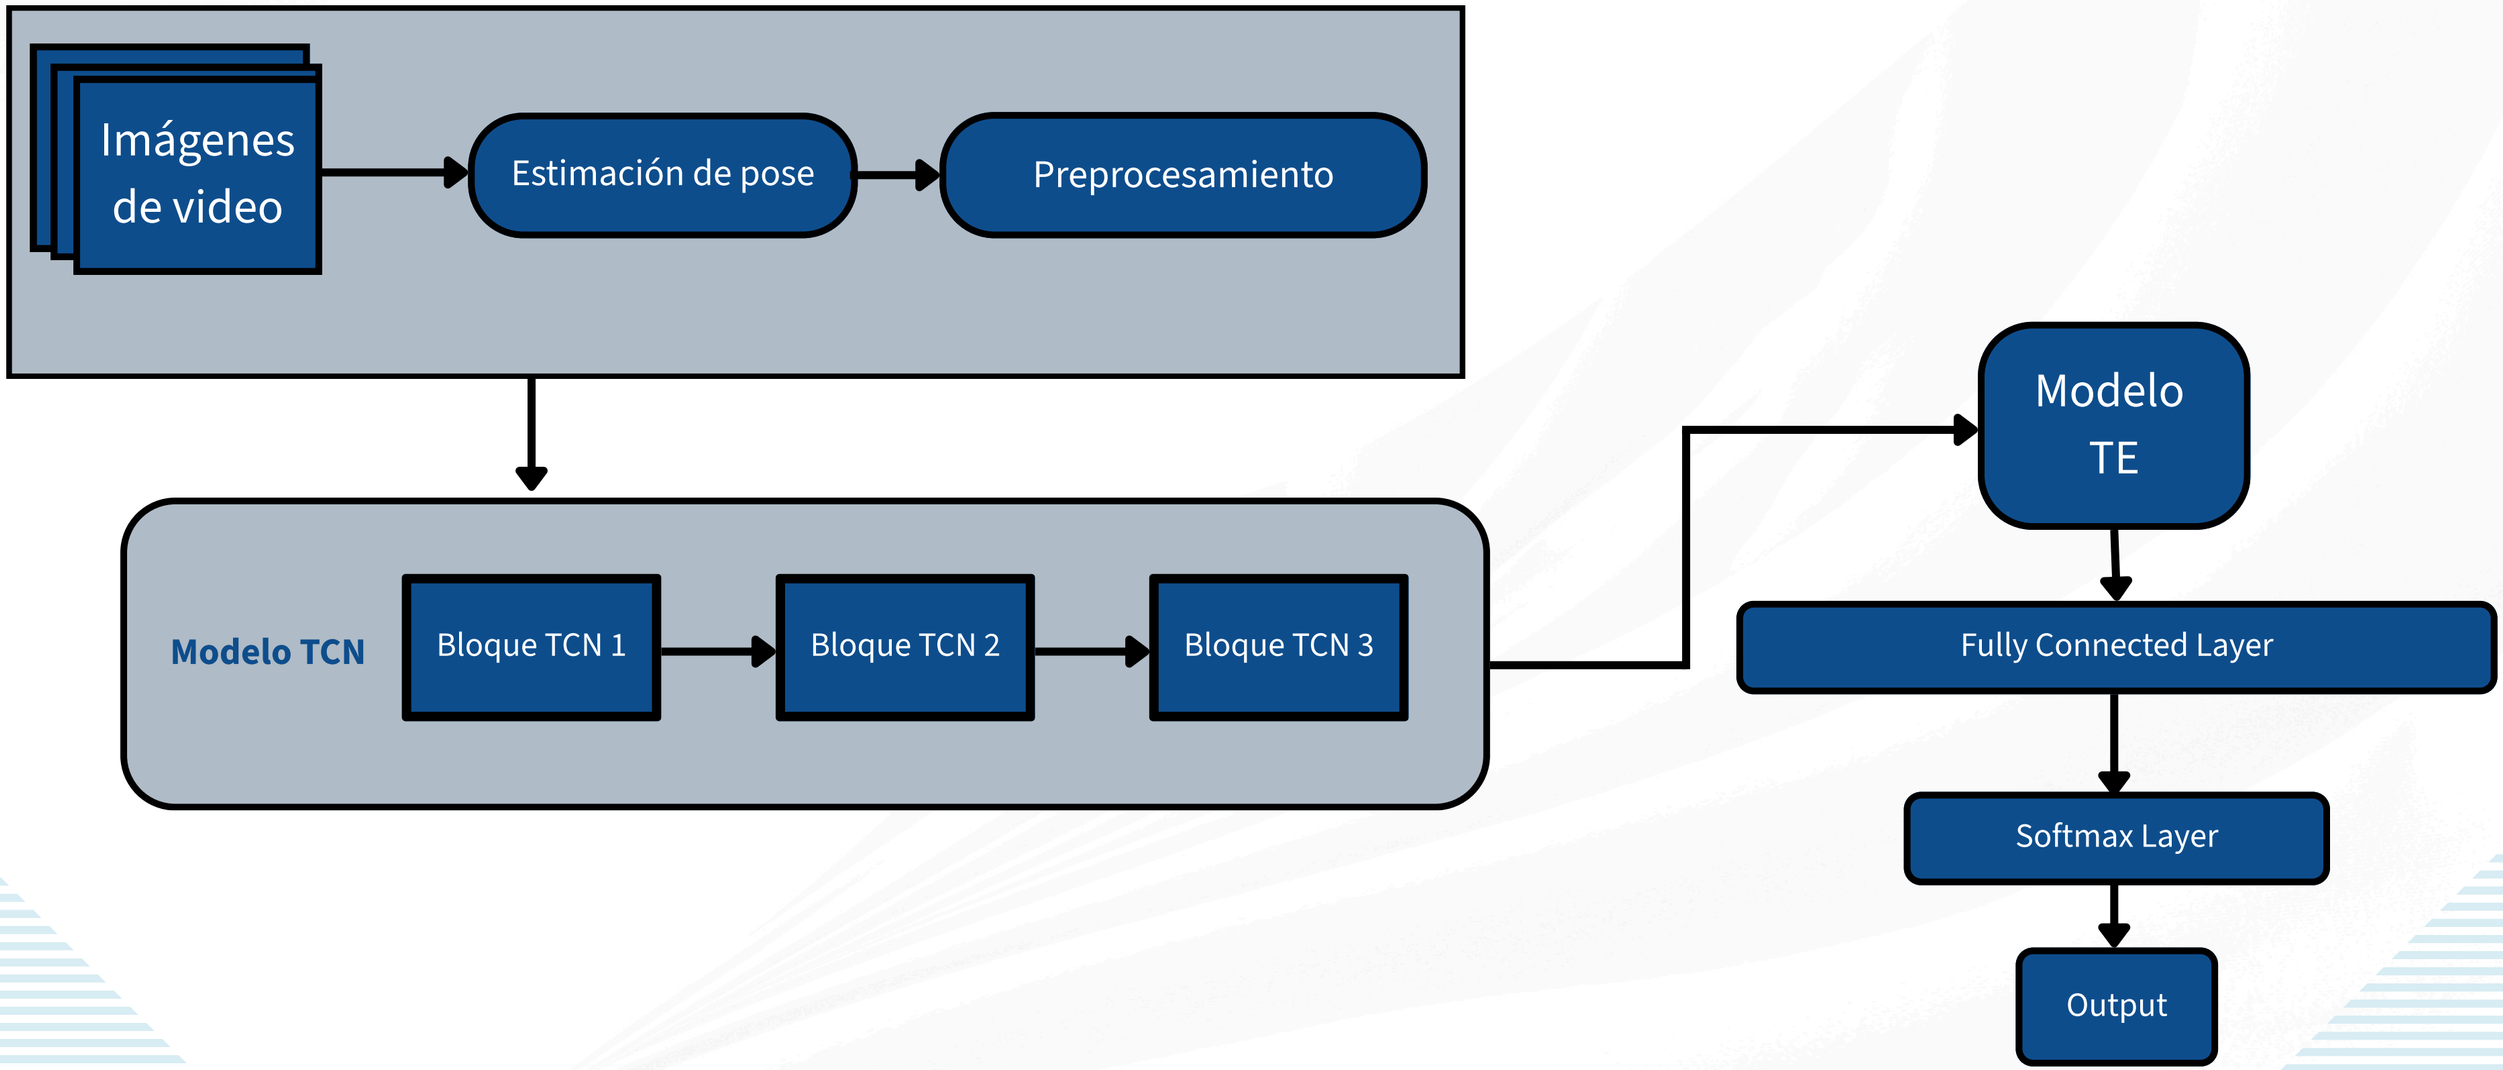
Variante A.1: Dado que un estimador de pose podría no identificar la pose de una persona en una imagen, se decidió utilizar la función matemática ***Cubic Spline interpolation*** para reconstruir la pose de esa imagen a partir de las poses correspondientes a la imagen anterior y a la imagen siguiente. Esta función se aplica durante la etapa de preprocesamiento del enfoque, luego de la estimación de poses de las imágenes. El objetivo es minimizar la pérdida de información enriqueciendo los datasets para el entrenamiento de la arquitectura.

Variante A.2: En los *datasets* utilizados en el área de detección de caídas, los videos que contienen caídas tienen menor duración que los que contienen una AVD, por lo que el número de imágenes etiquetadas como caída es muy inferior al número de imágenes etiquetadas como AVD. Dado que este enfoque no considera ninguna alternativa para tratar este desbalance de clases, se decidió utilizar la función de pérdida ***Weighted Focal Loss*** (WFL) durante la etapa de entrenamiento para tratar el desbalance de clases. De esta manera a la hora de entrenar la arquitectura, cuando la clasificación de una ventana de poses sea incorrecta, se penalizará de forma más agresiva si esa ventana corresponde a una caída, con el fin de dar más importancia a la detección errónea de caídas.

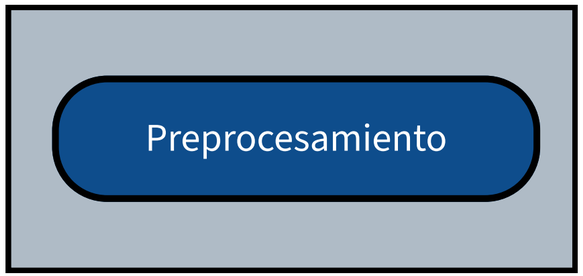
Variante A.3: Esta variante utiliza la función matemática ***Cubic Spline interpolation*** usada por la variante A.1, y la función ***WFL*** usada por la variante A.2, con el propósito de complementar las ventajas de estas variantes para lograr una variante más robusta.

Enfoque B

Este enfoque corresponde al propuesto por Yu et al., el cual utiliza el estimador de pose **YOLOv8-pose**, y una arquitectura híbrida que combina un modelo **TCN** (temporal convolutional network) y un modelo **TE** (transformer encoder), para determinar la ocurrencia de caídas.



Preprocesamiento



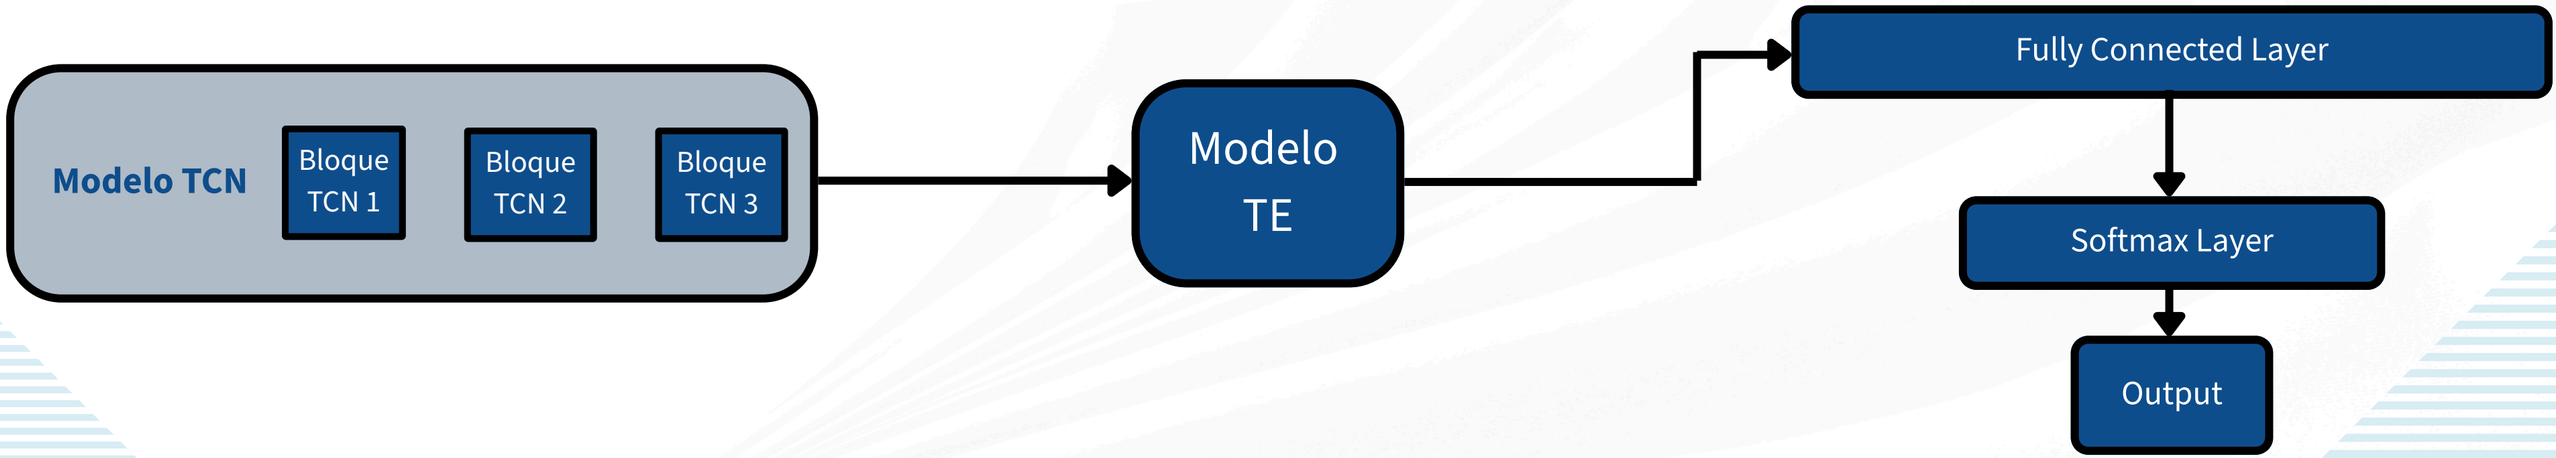
- Cargar en memoria las poses estimadas previamente
- Política de selección de la pose de la persona protagonista
- Heurística de detección de inicio y fin de caída
- Eliminación de poses posteriores a una caída
- Eliminación de puntos correspondientes a la cabeza
- Normalización de poses para ajustar coordenadas a una escala común
- Creación y etiquetado de ventanas deslizantes (tamaño de ventana dinámico según fps del dataset)
- Codificación de las etiquetas de las ventanas de pose (*One-Hot Encoding*)
- Particionamiento de las ventanas de pose según la metodología utilizada

Arquitectura del Enfoque B

Etapa TCN: Se aplica un modelo **TCN** a la ventana de poses recibida como entrada por la arquitectura. Este modelo está conformado por tres bloques **TCN**, que son modelos CNN modificados, los cuales permiten capturar relaciones temporales a corto, mediano y largo plazo de las poses en la ventana, y generar una secuencia de características temporales de las poses que se utiliza como entrada para la siguiente etapa.

Etapa TE: Las características extraídas por el modelo **TCN** alimentan un modelo **TE**. Este modelo utiliza mecanismos de atención para analizar estas características, y aprender cómo cada pose influye y se relaciona con las demás dentro de la ventana, independientemente de su distancia temporal. Este **TE** genera un único vector de características globales que condensan la evolución temporal de la ventana de poses recibida como entrada por la arquitectura. Este vector es usado como entrada para la siguiente etapa.

Etapa de clasificación: Esta etapa ocurre de manera análoga a la etapa de clasificación que es aplicada en el enfoque A .



Variante del Enfoque B

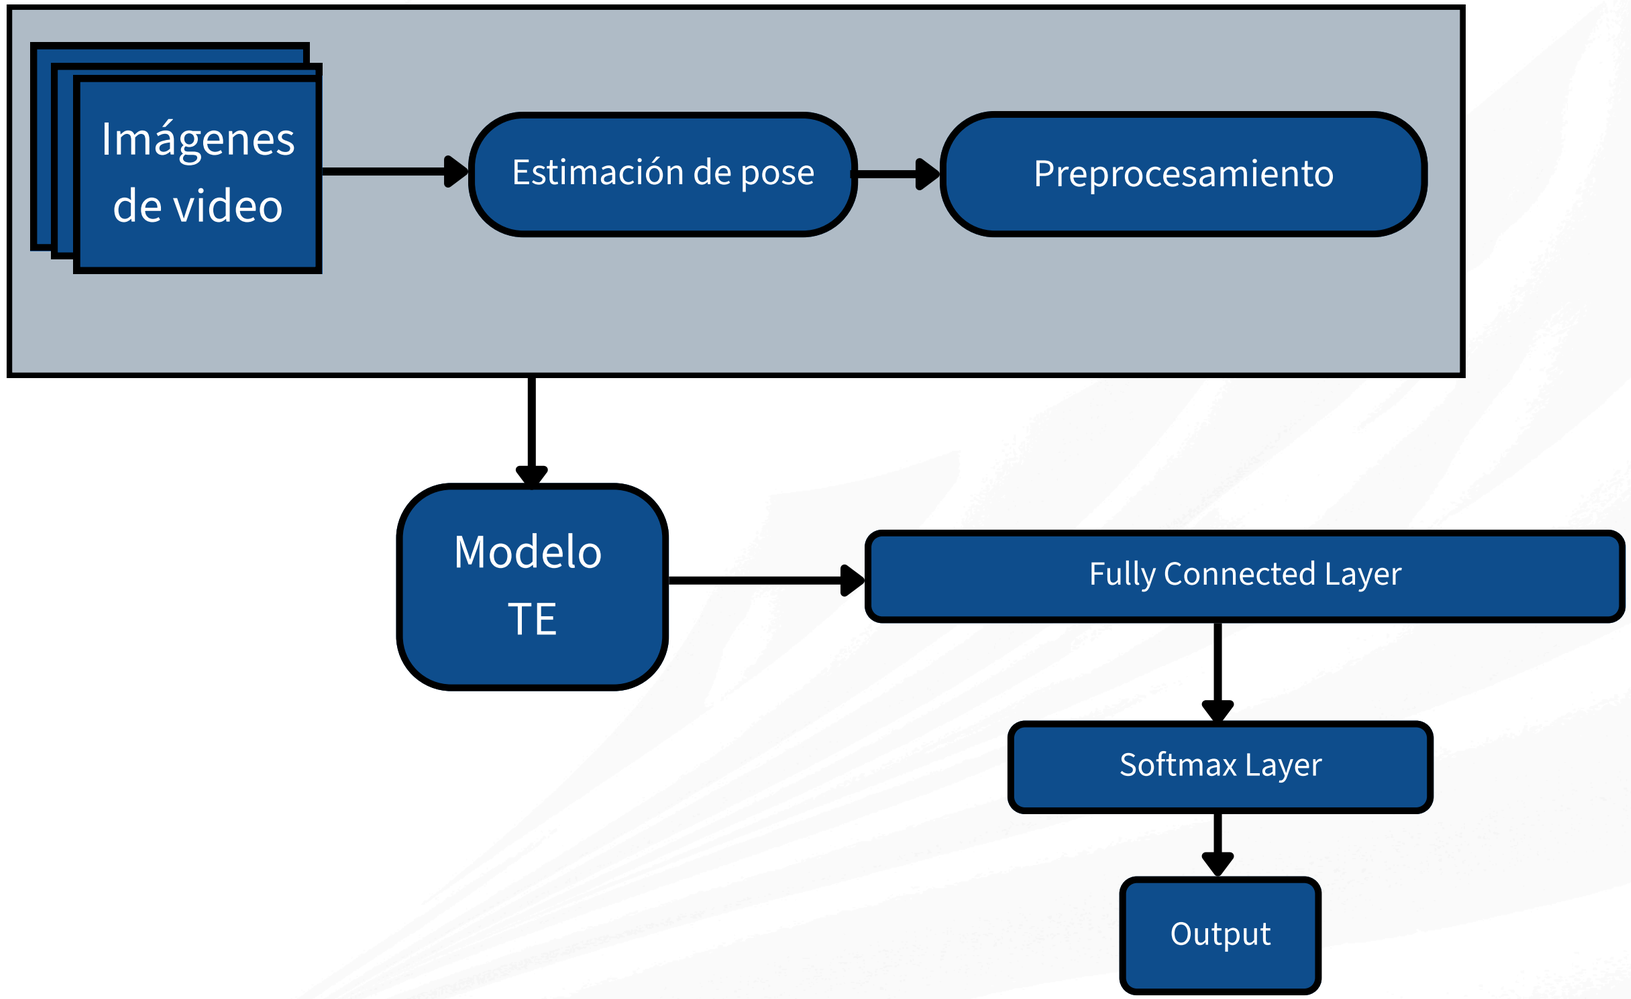
Con el objetivo de abordar algunas limitaciones del enfoque descrito, se definió una variante de este enfoque, la cual es presentada a continuación.

Variante B.1:

- Incorpora una política basada en la confianza de las poses, para identificar la pose de la persona que simula la caída o AVD.
- Por otro lado, para el caso de datasets que no poseen etiquetado a nivel de imagen, para identificar las poses que corresponden al inicio y fin de una caída se definieron dos heurísticas.
  - La primera heurística se encarga de detectar la pose que corresponde al inicio de una caída, considerando que el inicio de una caída ocurre cuando los puntos correspondientes a la cabeza se encuentran por debajo de la altura inicial de los puntos del hombro.
  - La segunda heurística se encarga de detectar la pose que corresponde al fin de una caída, considerando que el fin de una caída ocurre cuando los puntos de la cabeza llegan a la altura mínima que se obtiene durante el evento de una caída. De esta manera, las poses existentes entre la pose que inicia y la pose que finaliza una caída son etiquetadas como caída.
- Se añadió un soporte multi-estimador, definiendo una capa de entrada adaptativa para la arquitectura. Esta capa de entrada adapta su tamaño de acuerdo al número de puntos de articulación del estimador que se quiera utilizar.

Enfoque C

Este enfoque corresponde a una variante del enfoque B que fue propuesta por Yu et al., la cual utiliza el estimador de pose **YOLOv8-pose** para estimar las poses, y luego una arquitectura basada en un modelo **TE**, para determinar la ocurrencia de caídas.

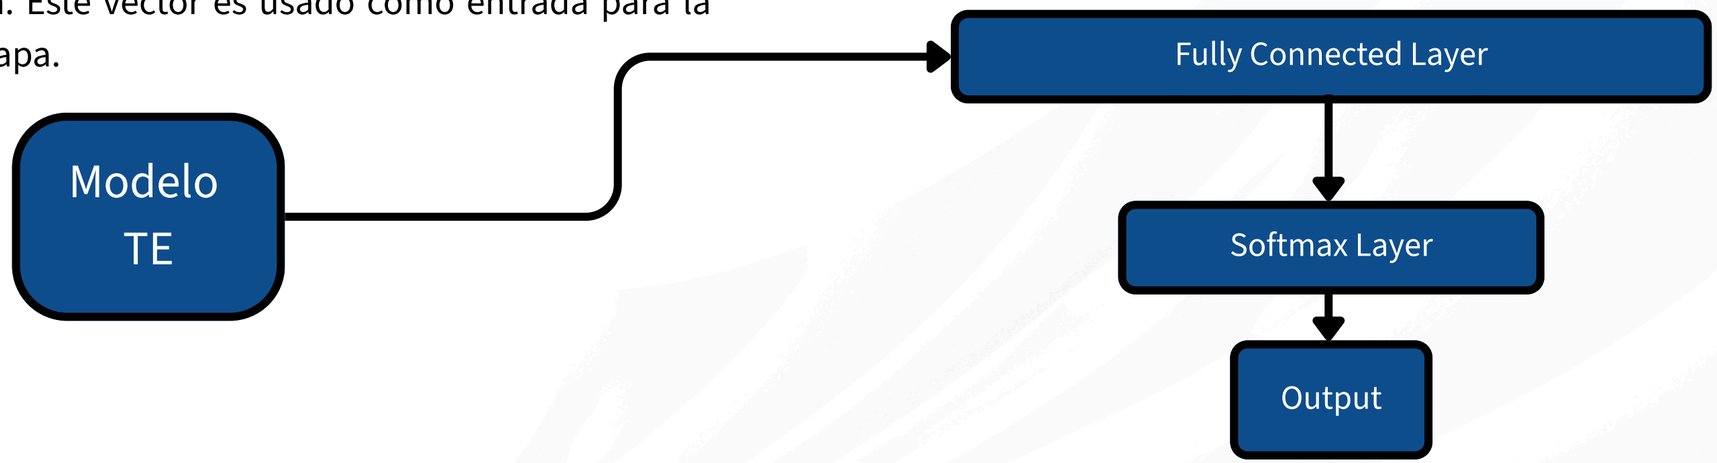


Arquitectura y variante del Enfoque C

Arquitectura

Etapa TE: Se aplica un modelo **TE** a la ventana de poses recibida como entrada por la arquitectura. Este modelo es análogo al modelo **TE** del enfoque B, en cuanto a su comportamiento y al vector de características generado como salida. Este vector es usado como entrada para la siguiente etapa.

Etapa de clasificación: Esta etapa ocurre de manera análoga a la etapa de clasificación que es aplicada en el enfoque A que ha sido descrito.



Variante

Se definió una variante de este enfoque, análoga a la variante presentada para el enfoque B

Metodologías de evaluación y validación

Particionamiento fijo (MPF)

Este particionamiento consiste en dividir a un *dataset* **D** en dos conjuntos: un conjunto para entrenamiento, y un conjunto para validación. El conjunto para entrenamiento contiene al 80% de las ventanas de poses de **D**, y el conjunto de validación contiene al 20% de las ventanas de **D**.

Validación cruzada (MVC)

Se divide el *dataset* **D** en **k** subconjuntos de igual tamaño denominados *folds*. Luego, se sigue un proceso iterativo de **k** pasos. En cada uno de estos pasos, se selecciona un *fold* distinto para actuar como conjunto de validación, mientras que los **k–1** folds restantes se agrupan para conformar el conjunto de entrenamiento.

Este procedimiento iterativo garantiza que cada ventana de pose del *dataset* **D** sea utilizada para validar la arquitectura del enfoque exactamente una vez.

Al finalizar los **k** pasos, se obtienen **k** valores distintos para las métricas. Finalmente, el valor definitivo de estas métricas se calcula promediando los **k** valores distintos.

De esta manera, la metodología ofrece valores más representativos del desempeño de la arquitectura utilizada.

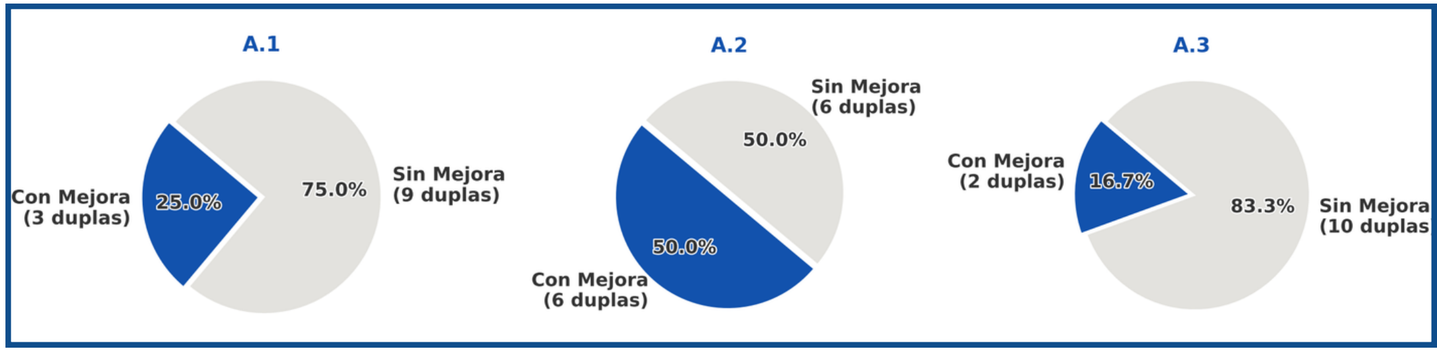
Métricas de Evaluación

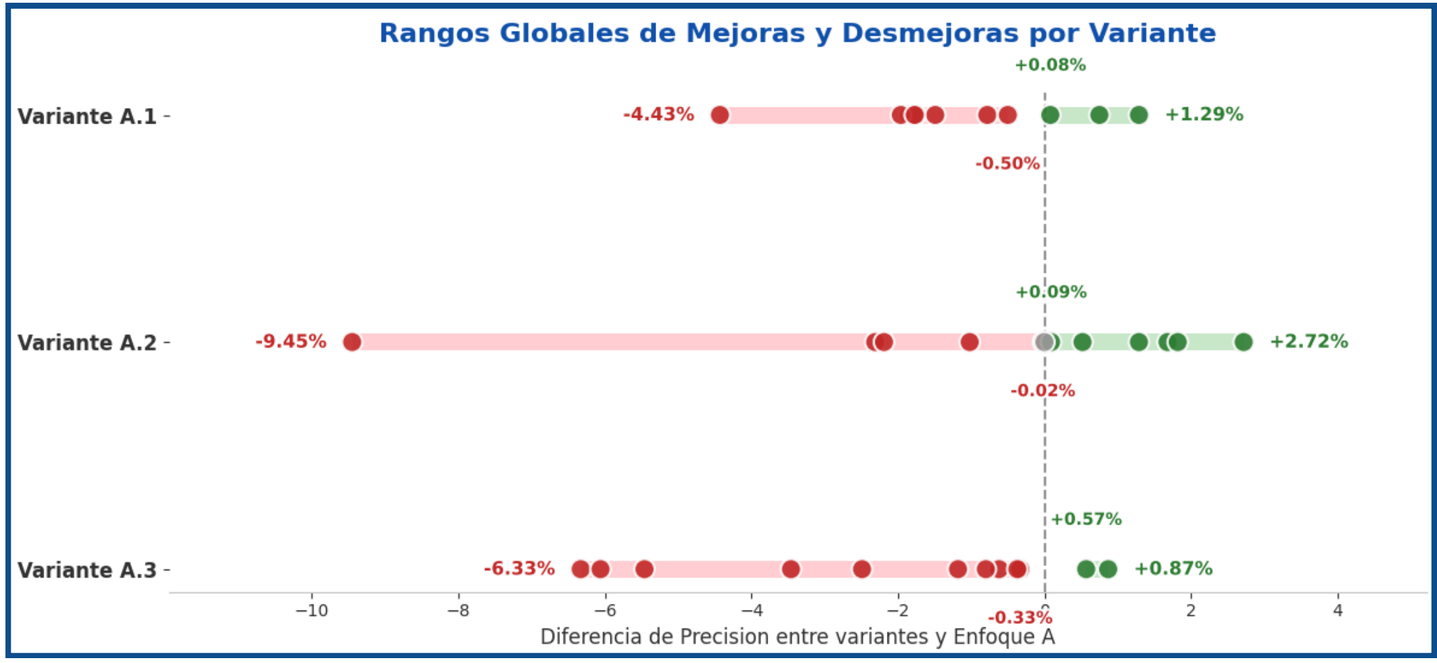
- **Accuracy:** Porcentaje total de ventanas de caídas y AVDs a detectar que fueron identificadas sobre el total de ventanas.
- **Precision:** Porcentaje de ventanas de caídas a detectar que fueron identificadas, en relación al total de ventanas identificadas como caída.
- **Sensitivity:** Porcentaje de ventanas de caídas a detectar que fueron identificadas, sobre el total de ventanas de caídas.
- **Specificity:** Porcentaje de ventanas de AVDs a detectar que fueron identificadas, en relación al total de ventanas de AVDs.

Experimentos de A - MPF

Precision

		P-MPF			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	97.34	**97.42**	**99.02***	96.72
	OpenPose	92.86*	91.1	91.84	87.4
	Mediapipe	98.95*	98.17	98.93	98.62
	YOLOv8-pose	94.76	**95.51**	**96.58***	**95.63**
Le2i	AlphaPose	92.25	90.4	**92.77***	91.07
	OpenPose	93.8*	92.01	91.49	93
	Mediapipe	95.29	93.8	**95.38***	94.92
	YOLOv8-pose	91.08	90.58	**93.8***	87.62
UR-Fall	AlphaPose	96.77*	92.34	87.32	90.44
	OpenPose	98.71	**100***	**100***	**99.28**
	Mediapipe	98.11*	96.15	98.11*	92.05
	YOLOv8-pose	99.26*	97.49	97.07	96.77

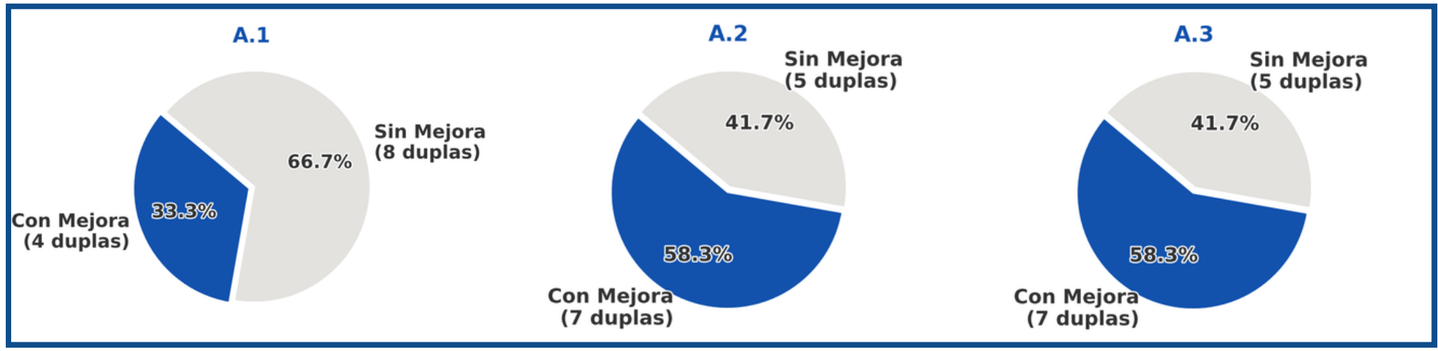


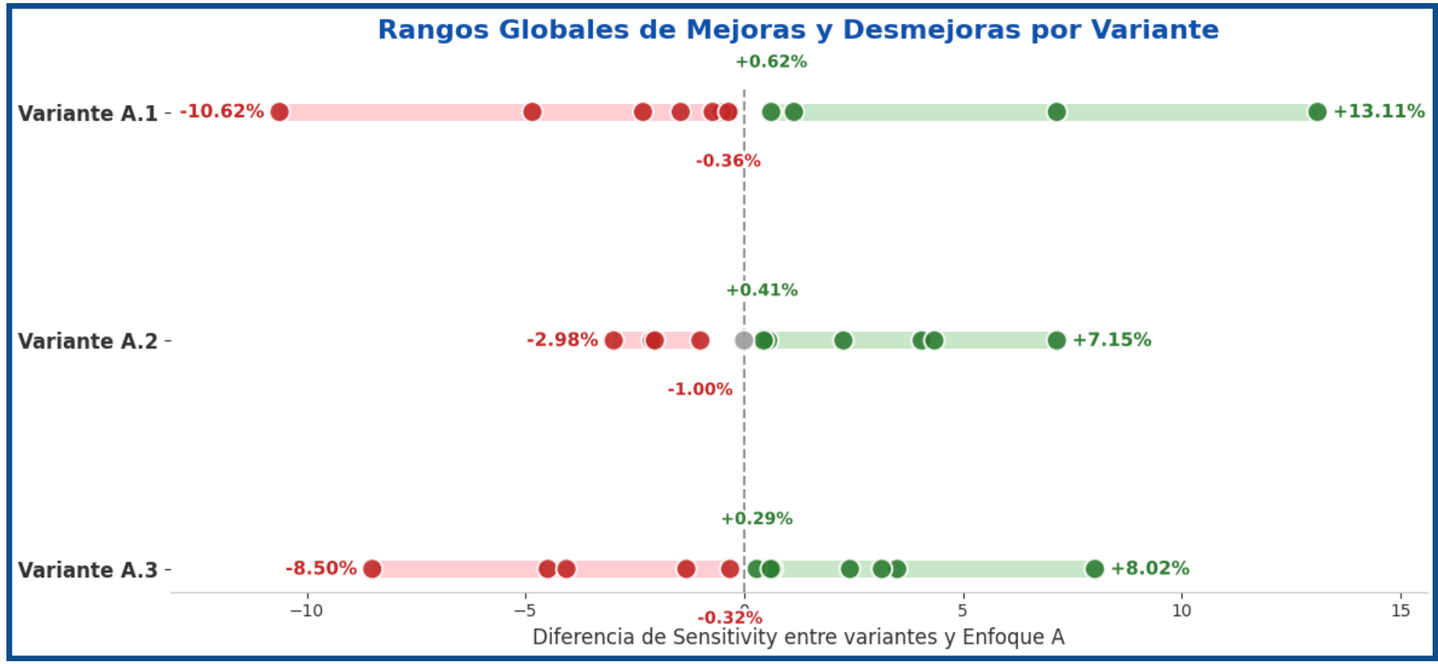


Experimentos de A - MPF

Sensitivity

		Se-MPF			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	95.56	95.2	**97.83***	**96.22**
	OpenPose	92.25	89.94	**92.66***	87.76
	Mediapipe	98.28	97.77	**98.83***	**98.57**
	YOLOv8-pose	92.41	90.96	**96.47***	**95.91**
Le2i	AlphaPose	91.98	**92.6***	89.87	90.66
	OpenPose	93.1	**94.24***	90.12	**93.71**
	Mediapipe	97.55*	96.83	95.51	97.23
	YOLOv8-pose	95.49	90.65	**95.94***	86.99
UR-Fall	AlphaPose	82.6	**95.71***	**86.95**	**90.62**
	OpenPose	92.85	**100***	**100***	**96**
	Mediapipe	88.88	78.26	88.88	**91.3***
	YOLOv8-pose	96.65*	96.29	95.65	92.59

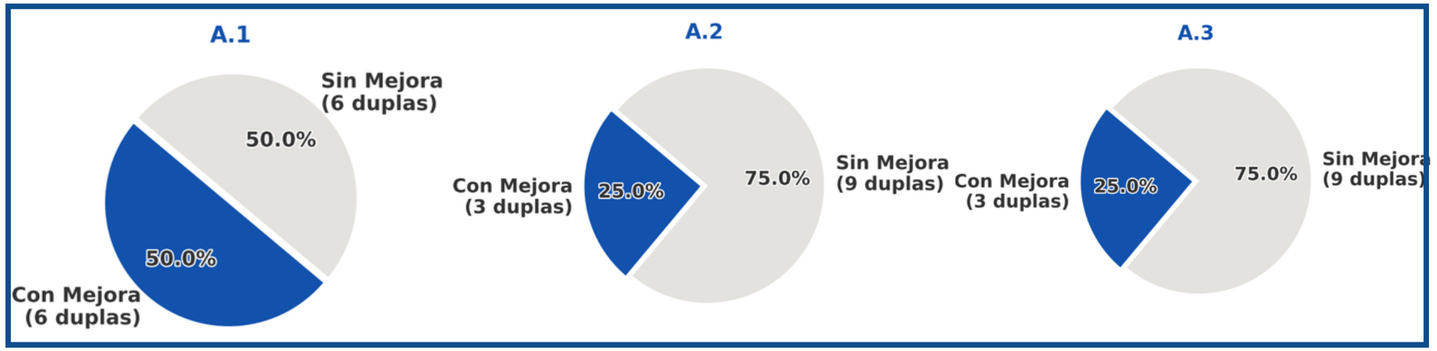


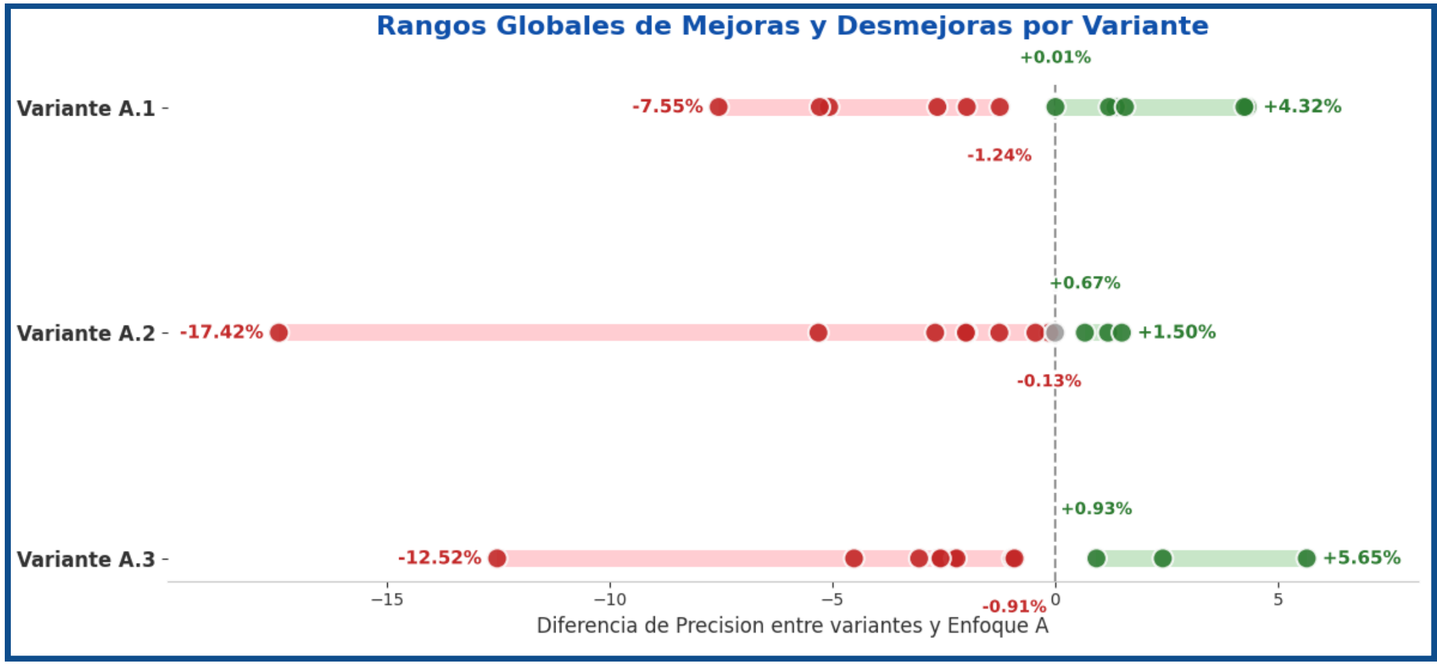


Experimentos de A - MVC

Precision

		P-MVC			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	63.89*	58.82	62.64	61.31
	OpenPose	45.44	**46.8***	45.31	43.18
	Mediapipe	65.73*	64.49	63.76	61.22
	YOLOv8-pose	57.33	**57.34***	56.89	54.28
Le2i	AlphaPose	63.03	**64.24**	**64.22**	**68.68***
	OpenPose	65.08	**66.65***	65.08	62.87
	Mediapipe	64.94	59.66	**66.44***	63.98
	YOLOv8-pose	69.85	67.21	**70.52***	67.28
UR-Fall	AlphaPose	88.73*	86.75	86.04	87.82
	OpenPose	81.06*	73.51	63.64	68.54
	Mediapipe	72.56	**76.88***	67.25	**73.49**
	YOLOv8-pose	86.84	**91.09***	84.84	**89.26**

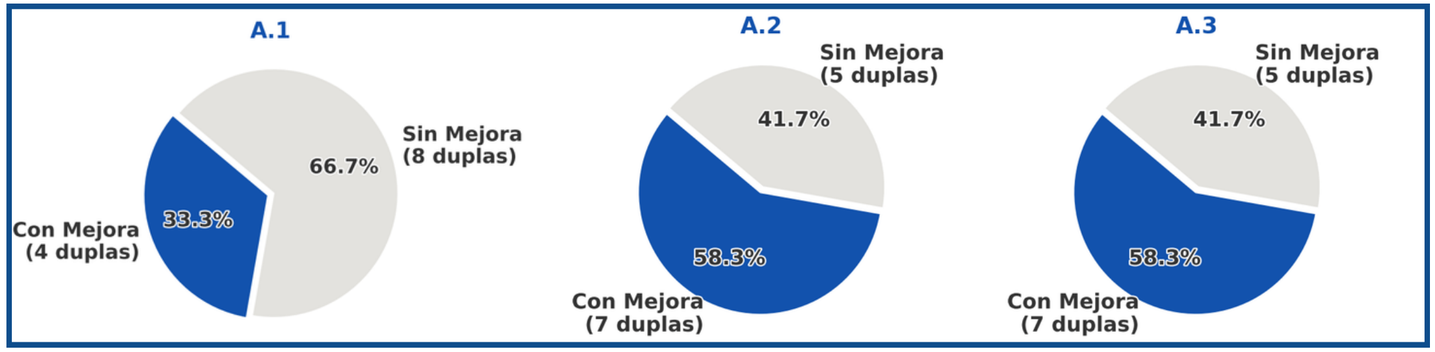


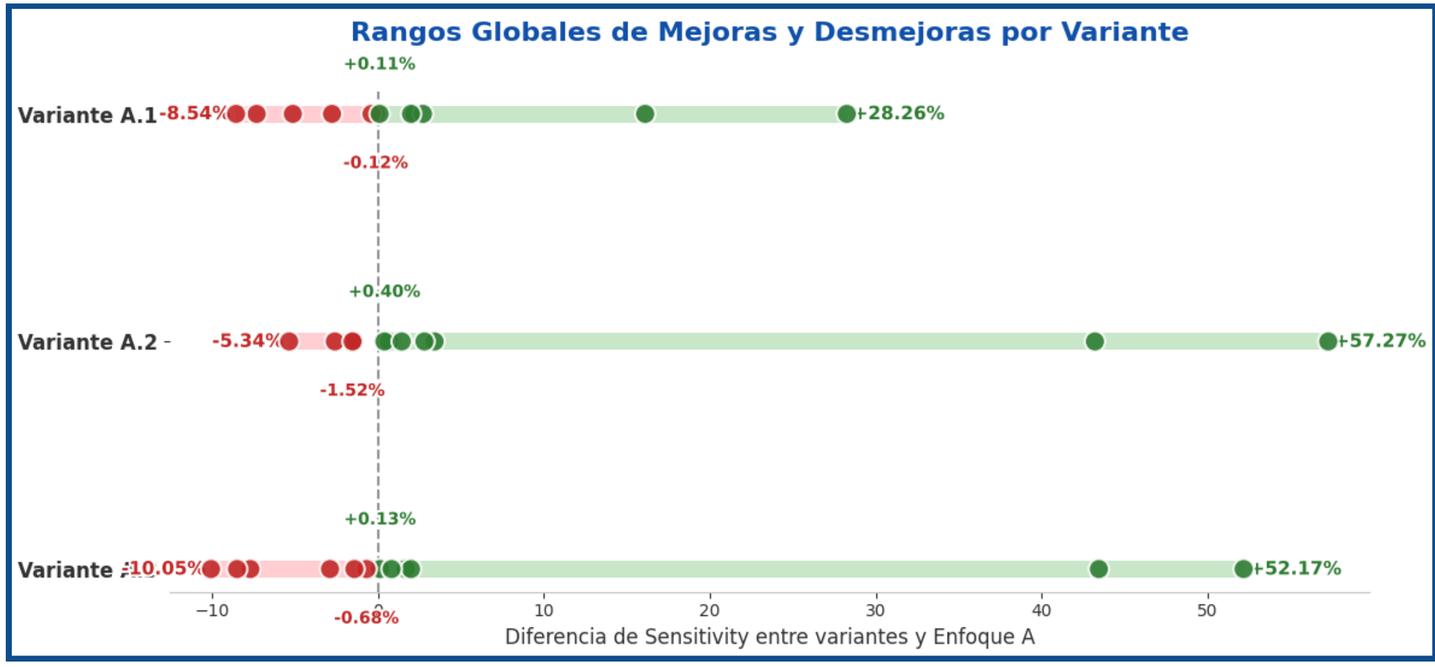


Experimentos de A - MVC

Sensitivity

		Se-MVC			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	65.13	60.01	**65.99***	**65.26**
	OpenPose	46.78	46.66	**47.46***	46.1
	Mediapipe	68.1*	65.34	66.56	66.69
	YOLOv8-pose	57.59	57.21	**61.01***	**59.26**
Le2i	AlphaPose	75.43*	68.13	72.84	67.75
	OpenPose	75.29	**77.5***	**75.69**	72.41
	Mediapipe	82.6*	74.06	81.08	72.55
	YOLOv8-pose	79.4	**82.12***	74.06	70.92
UR-Fall	AlphaPose	82.88	**84.88**	**85.69***	**84.88**
	OpenPose	31.3	**59.56**	**88.57***	**83.47**
	Mediapipe	35.68	**51.79**	**78.89**	**79.13***
	YOLOv8-pose	81.73	**81.84**	**83.17***	**82.56**





Experimentos de A

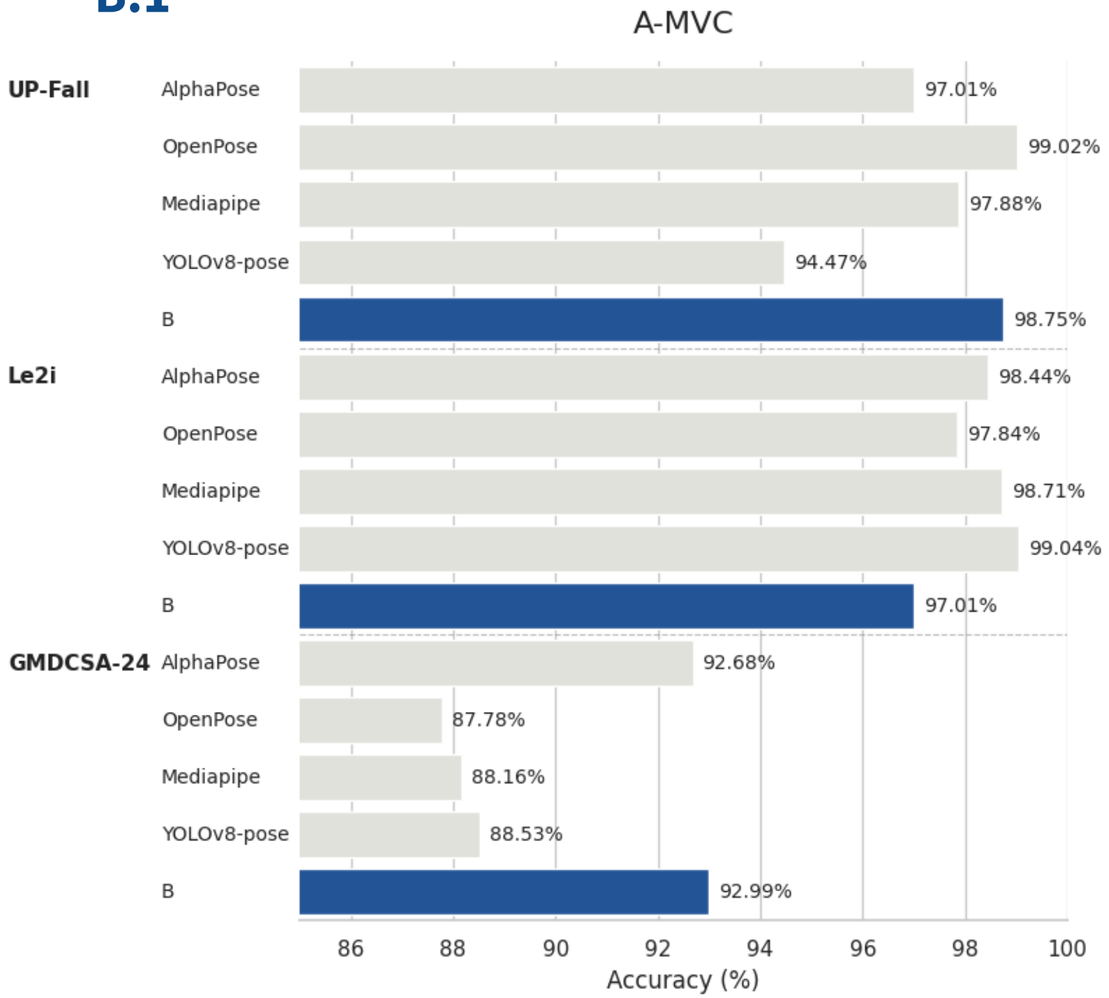
Comparativa entre metodologías

Precision		P-MPF - P-MVC			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	**33.45**	**38.6**	**36.38**	**35.41**
	OpenPose	**47.42**	**44.3**	**46.53**	**44.22**
	Mediapipe	**33.22**	**33.68**	**35.17**	**37.4**
	YOLOv8-pose	**37.43**	**38.17**	**39.69**	**41.35**
Le2i	AlphaPose	**29.22**	**26.16**	**28.55**	**22.39**
	OpenPose	**28.72**	**25.36**	**26.41**	**30.13**
	Mediapipe	**30.35**	**34.14**	**28.94**	**30.94**
	YOLOv8-pose	**21.23**	**23.37**	**23.28**	**20.34**
UR-Fall	AlphaPose	**8.04**	**5.59**	**1.28**	**2.62**
	OpenPose	**17.65**	**26.49**	**36.36**	**30.74**
	Mediapipe	**25.55**	**19.27**	**30.86**	**18.56**
	YOLOv8-pose	**12.42**	**6.4**	**12.23**	**7.51**

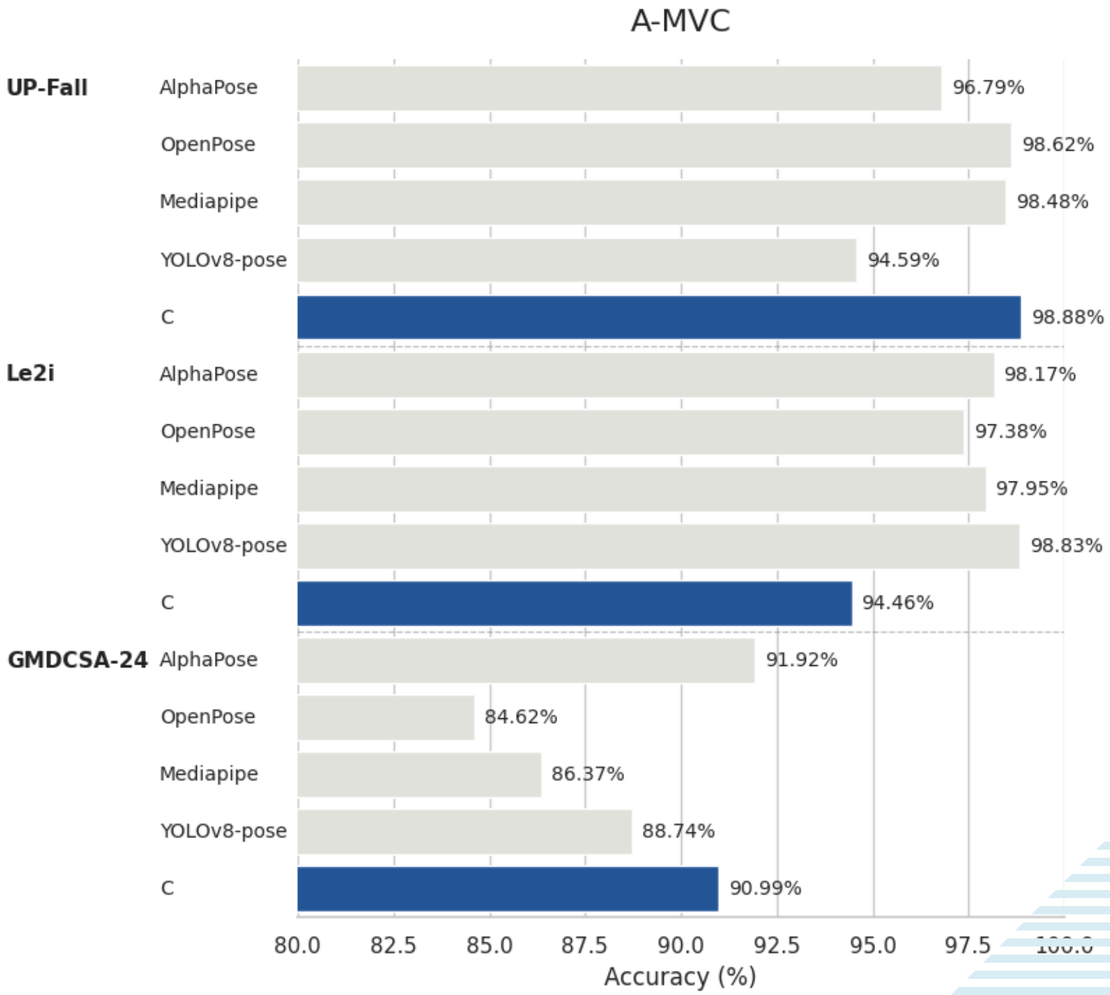
Sensitivity		Se-MPF - Se-MVC			
Dataset	Estimador	A	A.1	A.2	A.3
UP-Fall	AlphaPose	**30.43**	**35.19**	**31.84**	**30.96**
	OpenPose	**45.47**	**43.28**	**45.2**	**41.66**
	Mediapipe	**30.18**	**32.43**	**32.27**	**31.88**
	YOLOv8-pose	**34.82**	**33.75**	**35.46**	**36.65**
Le2i	AlphaPose	**16.55**	**24.47**	**17.03**	**22.91**
	OpenPose	**17.81**	**16.74**	**14.43**	**21.3**
	Mediapipe	**14.95**	**22.77**	**14.43**	**24.68**
	YOLOv8-pose	**16.09**	**8.53**	**21.88**	**16.07**
UR-Fall	AlphaPose	**-0.28**	**10.83**	**1.26**	**5.74**
	OpenPose	**61.55**	**40.44**	**11.43**	**12.53**
	Mediapipe	**53.2**	**26.47**	**9.99**	**12.17**
	YOLOv8-pose	**14.92**	**14.45**	**12.48**	**10.03**

Experimentos de B y C - MVC

B.1

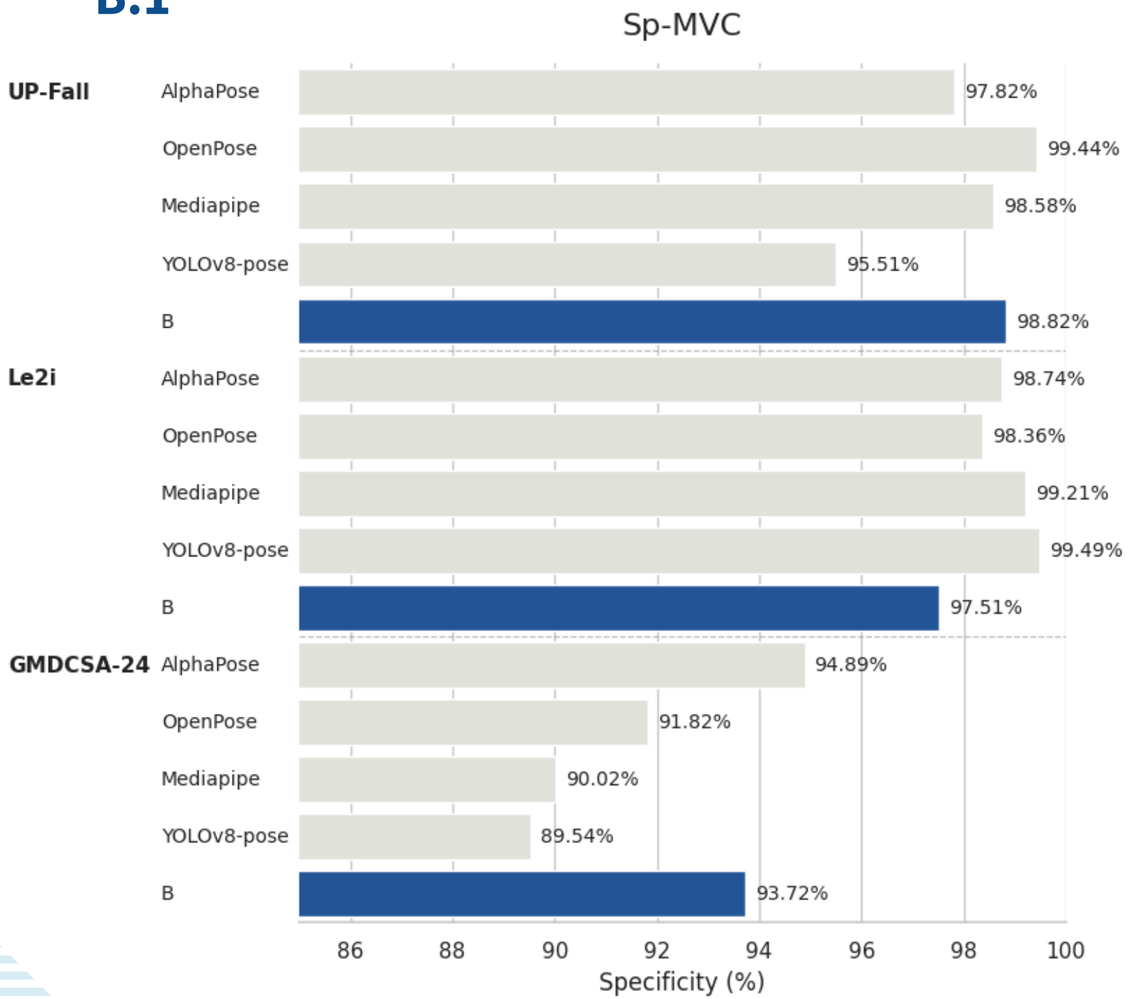


C.1

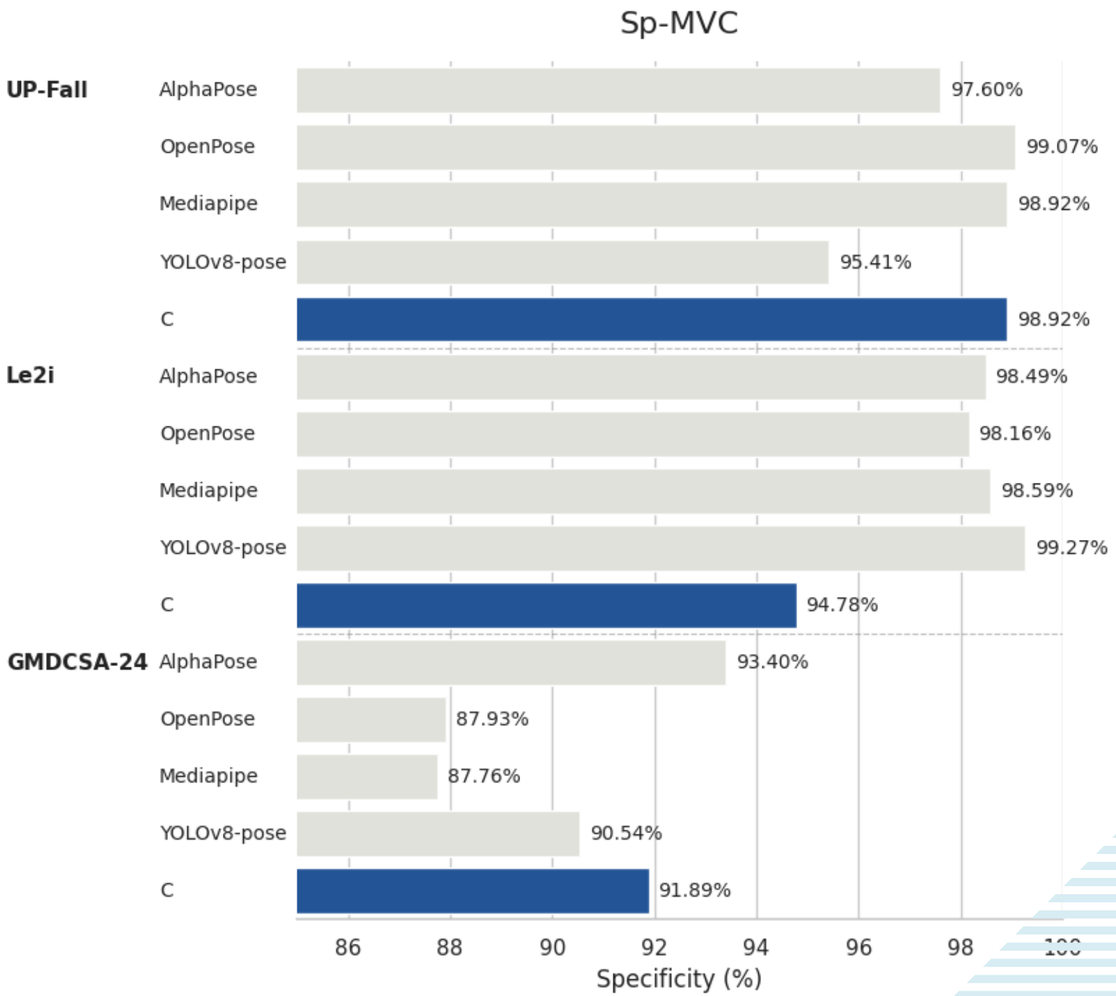


Experimentos de B y C - MVC

B.1

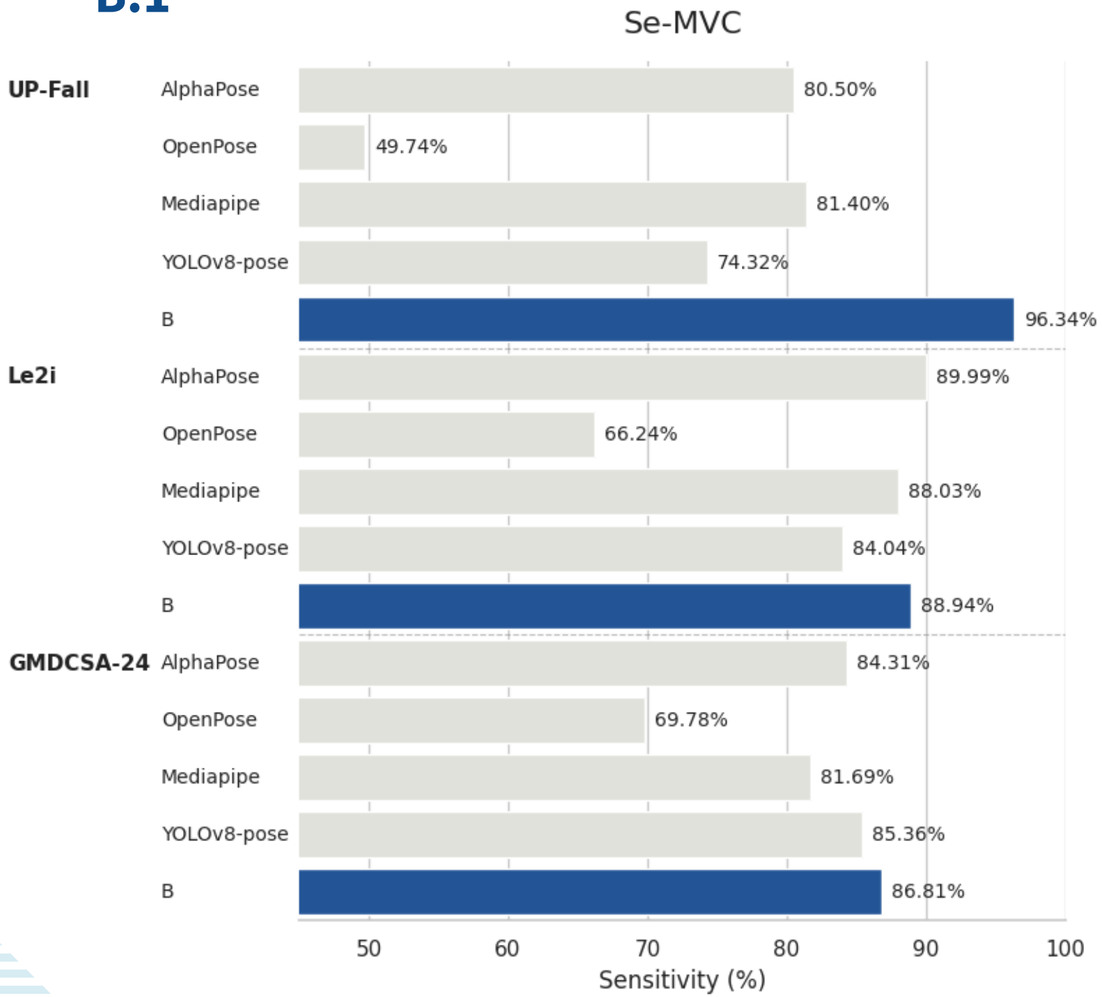


C.1

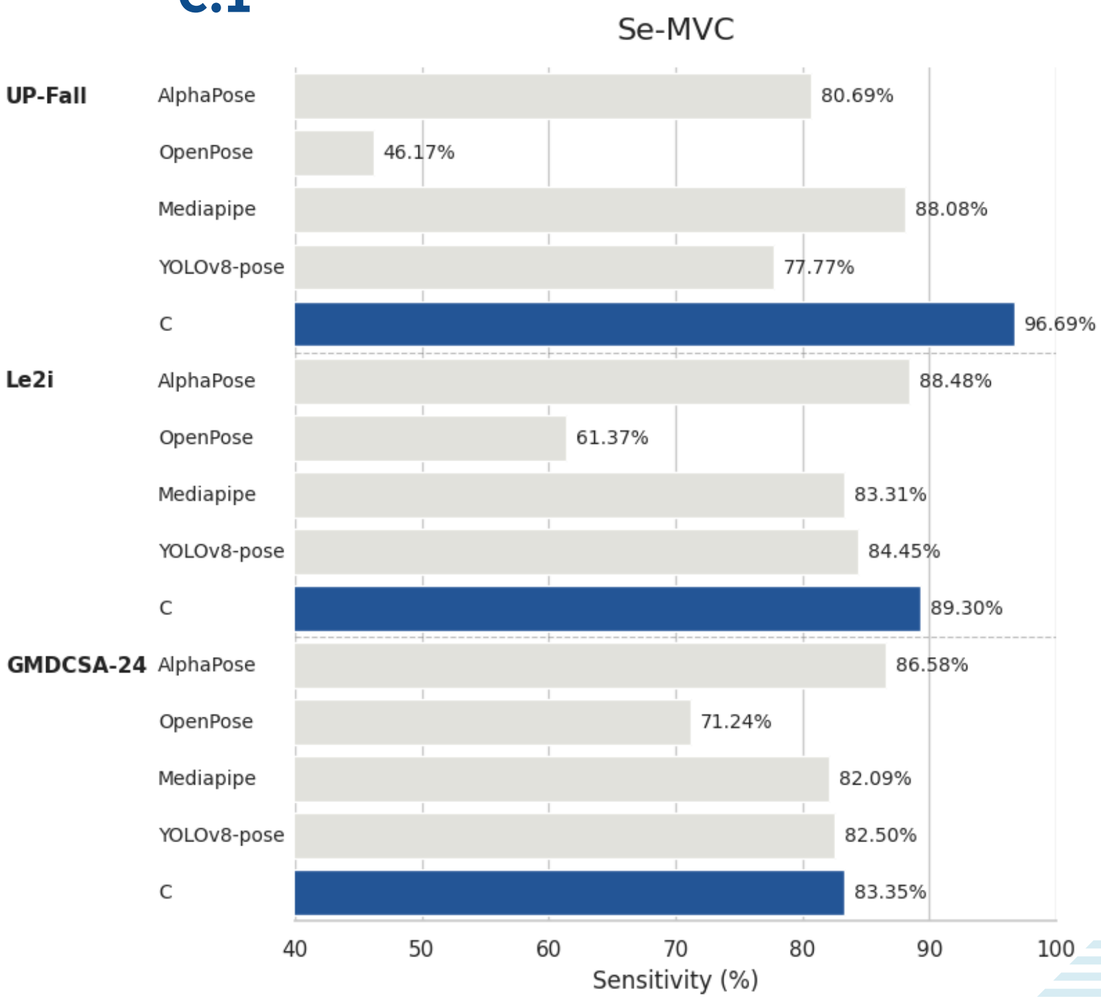


Experimentos de B y C - MVC

B.1

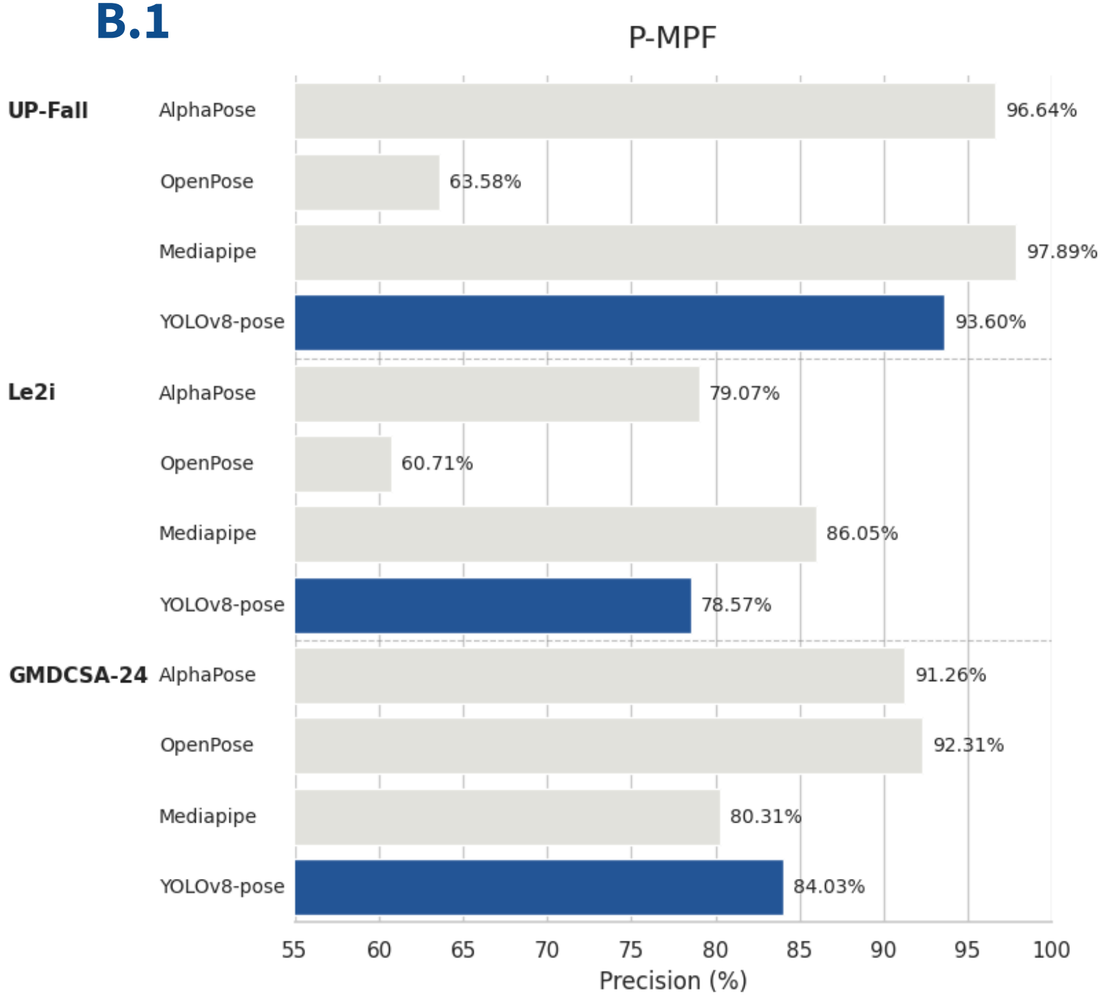


C.1

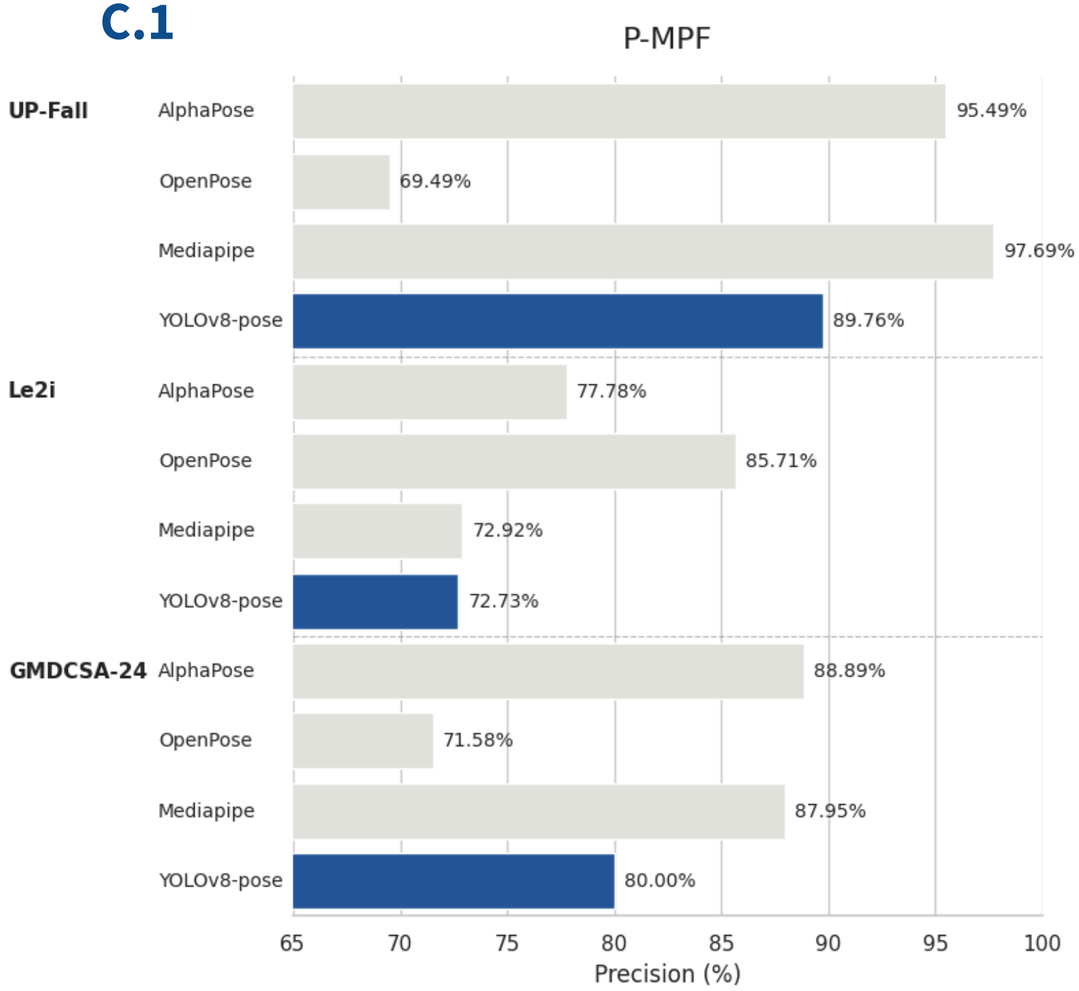


Experimentos de B y C - MPF

B.1

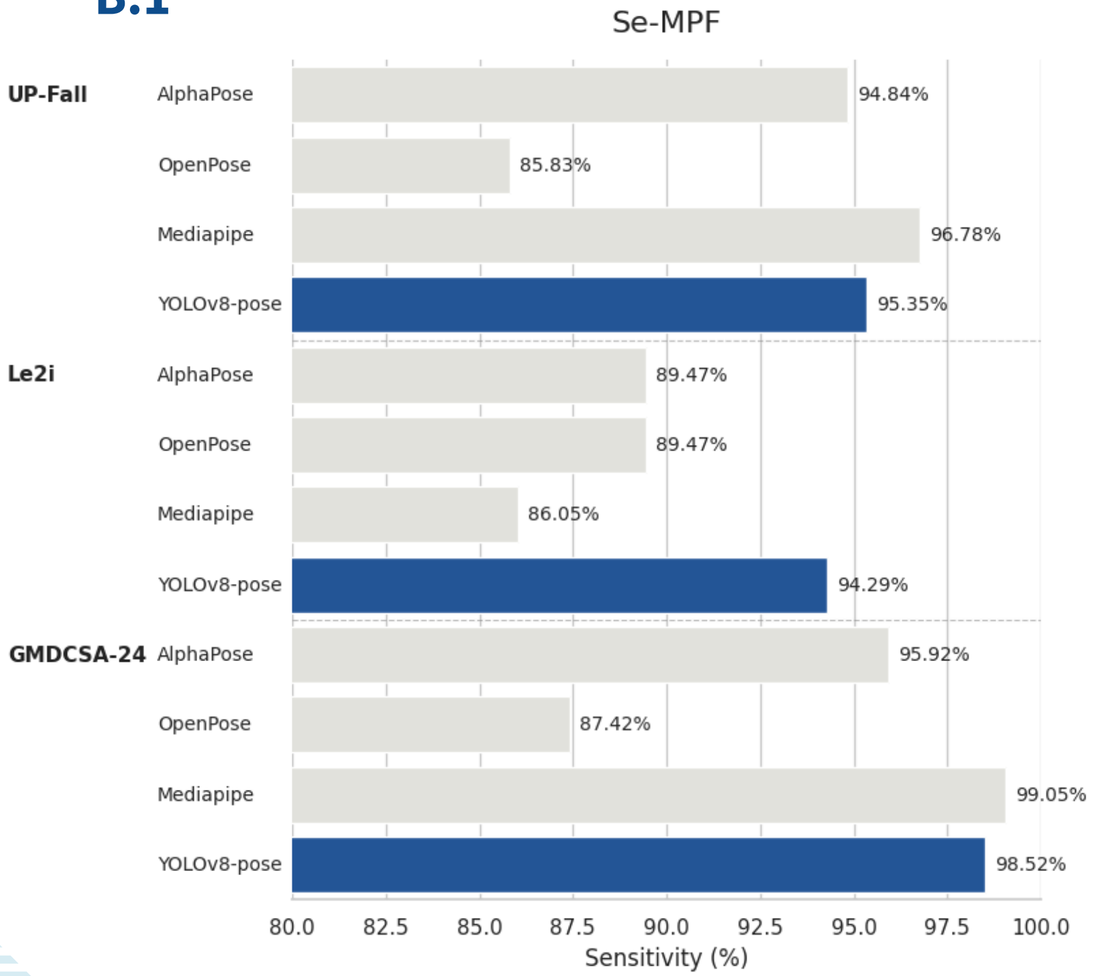


C.1

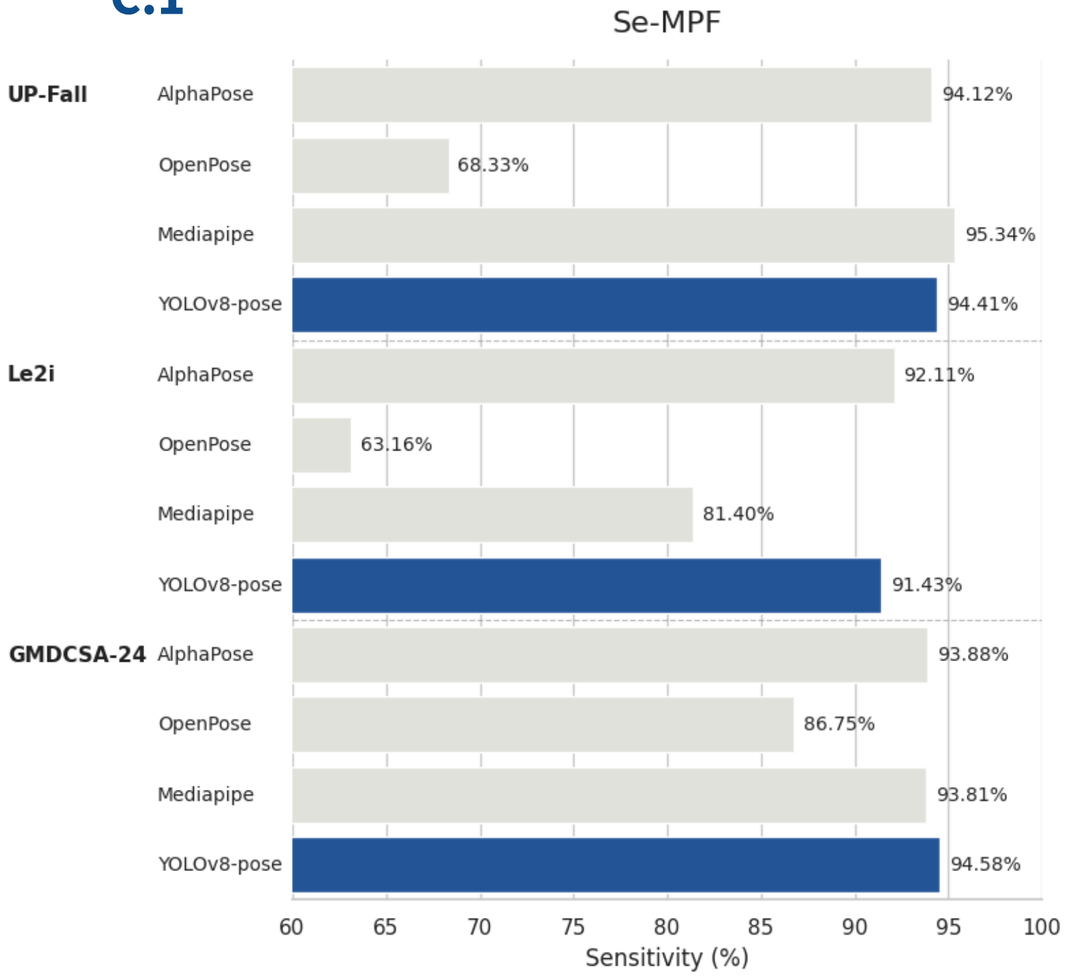


Experimentos de B y C - MPF

B.1



C.1



Experimentos de B.1

Comparativa entre metodologías

	P-MPF - P-MVC	
Dataset	Estimador	B.1
UP-Fall	AlphaPose	**27.84**
	OpenPose	**20.13**
	Mediapipe	**20.34**
	YOLOv8-pose	**47.60**
Le2i	AlphaPose	**10.84**
	OpenPose	**18.84**
	Mediapipe	**4.12**
	YOLOv8-pose	**-5.04**
GMDCSA-24	AlphaPose	**9.51**
	OpenPose	**25.89**
	Mediapipe	**10.40**
	YOLOv8-pose	**14.44**

	Se-MPF - Se-MVC	
Dataset	Estimador	B.1
UP-Fall	AlphaPose	**14.99**
	OpenPose	**19.75**
	Mediapipe	**16.29**
	YOLOv8-pose	**15.44**
Le2i	AlphaPose	**-12.21**
	OpenPose	**19.47**
	Mediapipe	**-15.11**
	YOLOv8-pose	**-11.31**
GMDCSA-24	AlphaPose	**4.58**
	OpenPose	**1.80**
	Mediapipe	**6.26**
	YOLOv8-pose	**-5.36**

Experimentos de C.1

Comparativa entre metodologías

	P-MPF - P-MVC	
Dataset	Estimador	C.1
UP-Fall	AlphaPose	**29.44**
	OpenPose	**37.44**
	Mediapipe	**18.59**
	YOLOv8-pose	**40.27**
Le2i	AlphaPose	**14.09**
	OpenPose	**47.19**
	Mediapipe	**2.13**
	YOLOv8-pose	**-5.32**
GMDCSA-24	AlphaPose	**11.35**
	OpenPose	**14.90**
	Mediapipe	**21.82**
	YOLOv8-pose	**9.37**

	Se-MPF - Se-MVC	
Dataset	Estimador	C.1
UP-Fall	AlphaPose	**13.43**
	OpenPose	**22.16**
	Mediapipe	**7.26**
	YOLOv8-pose	**16.64**
Le2i	AlphaPose	**3.63**
	OpenPose	**1.79**
	Mediapipe	**-1.91**
	YOLOv8-pose	**6.98**
GMDCSA-24	AlphaPose	**7.30**
	OpenPose	**15.51**
	Mediapipe	**11.72**
	YOLOv8-pose	**12.08**

Comparativa entre enfoques y variantes - MVC

		P-MVC					
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	63.89 ± 1.85	58.82 ± 1.97	62.64 ± 1.47	61.31 ± 1.57	**68.80 ± 14.60**	66.05 ± 13.08*
	OpenPose	45.44 ± 2.33*	**46.80 ± 2.60**	45.31 ± 3.17	43.18 ± 0.59	43.45 ± 7.97	32.05 ± 8.83
	Mediapipe	65.73 ± 4.67	64.49 ± 1.61	63.76 ± 0.71	61.22 ± 3.07	77.55 ± 15.73*	**79.10 ± 5.53**
	YOLOv8-pose	57.33 ± 3.93*	**57.34 ± 0.67**	56.89 ± 0.12	54.28 ± 2.36	46.00 ± 2.52	49.49 ± 9.56
Le2i	AlphaPose	63.03 ± 1.44	64.24 ± 5.24	64.22 ± 2.20	**68.68 ± 5.78**	68.23 ± 18.20*	63.69 ± 16.69
	OpenPose	65.08 ± 2.75*	**66.65 ± 2.75**	65.08 ± 4.72	62.87 ± 4.12	41.87 ± 10.04	38.52 ± 11.93
	Mediapipe	64.94 ± 3.21	59.66 ± 3.44	66.44 ± 1.30	63.98 ± 3.66	**81.93 ± 3.87**	70.79 ± 2.04*
	YOLOv8-pose	69.85 ± 1.09	67.21 ± 1.44	70.52 ± 0.31	67.28 ± 6.01	**83.61 ± 4.39**	78.05 ± 3.41*

Cantidad de mejores duplas	
A	**0**
A.1	**3**
A.2	**0**
A.3	**1**
B.1	**3**
C.1	**1**

Comparativa entre enfoques y variantes - MVC

		Se-MVC					
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	65.13 ± 1.37	60.01 ± 0.73	65.99 ± 3.43	65.26 ± 3.28	80.50 ± 3.76*	**80.69 ± 5.54**
	OpenPose	46.78 ± 3.78	46.66 ± 1.82	47.46 ± 2.28*	46.10 ± 0.80	**49.74 ± 8.64**	46.17 ± 4.18
	Mediapipe	68.10 ± 2.59	65.34 ± 2.28	66.56 ± 1.32	66.69 ± 1.96	81.40 ± 9.48*	**88.08 ± 6.69**
	YOLOv8-pose	57.59 ± 2.82	57.21 ± 1.78	61.01 ± 0.59	59.26 ± 4.62	74.32 ± 9.56*	**77.77 ± 6.61**
Le2i	AlphaPose	75.43 ± 4.58	68.13 ± 16.98	72.84 ± 4.71	67.75 ± 16.10	**89.99 ± 3.72**	88.48 ± 6.41*
	OpenPose	75.29 ± 17.93	**77.50 ± 10.18**	75.69 ± 12.66*	72.41 ± 8.84	66.24 ± 7.77	61.37 ± 7.72
	Mediapipe	82.60 ± 4.84	74.06 ± 8.89	81.08 ± 1.23	72.55 ± 11.71	**88.03 ± 3.38**	83.31 ± 3.21*
	YOLOv8-pose	79.40 ± 6.53	82.12 ± 5.03	74.06 ± 6.40	70.92 ± 2.52	84.04 ± 0.43*	**84.45 ± 2.78**

Cantidad de mejores duplas	
A	**0**
A.1	**1**
A.2	**0**
A.3	**0**
B.1	**3**
C.1	**4**

Comparativa entre enfoques y variantes - MPF

		P-MPF					
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	97.34	97.42*	**99.02**	96.72	96.64	95.49
	OpenPose	**92.86**	91.1	91.84*	87.4	63.58	69.49
	Mediapipe	**98.95**	98.17	98.93*	98.62	97.89	97.69
	YOLOv8-pose	94.76	95.51	**96.58**	95.63*	93.6	89.76
Le2i	AlphaPose	92.25*	90.4	**92.77**	91.07	79.07	77.78
	OpenPose	**93.8**	92.01	91.49	93*	60.71	85.71
	Mediapipe	95.29*	93.8	**95.38**	94.92	86.05	72.92
	YOLOv8-pose	91.08*	90.58	**93.8**	87.62	78.57	72.73

Cantidad de mejores duplas	
A	**3**
A.1	**0**
A.2	**5**
A.3	**0**
B.1	**0**
C.1	**0**

Comparativa entre enfoques y variantes - MPF

		Se-MPF					
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	95.56	95.2	**97.83**	96.22*	94.84	94.12
	OpenPose	92.25*	89.94	**92.66**	87.76	85.83	68.33
	Mediapipe	98.28	97.77	**98.83**	98.57*	96.78	95.34
	YOLOv8-pose	92.41	90.96	**96.47**	95.91*	95.35	94.41
Le2i	AlphaPose	91.98	**92.6**	89.87	90.66	89.47	92.11*
	OpenPose	93.1	**94.24**	90.12	93.71*	89.47	63.16
	Mediapipe	**97.55**	96.83	95.51	97.23*	86.05	81.4
	YOLOv8-pose	95.49*	90.65	**95.94**	86.99	94.29	91.43

Cantidad de mejores duplas	
A	**1**
A.1	**2**
A.2	**5**
A.3	**0**
B.1	**0**
C.1	**0**

Comparativa entre enfoques y variantes

Metodología de evaluación y validación basada en un esquema de particionamiento fijo

Mejoras respecto a A (en duplas)	A	A.1	A.2	A.3	B.1	C.1
Precision	**3**	**0**	**5**	**0**	**0**	**0**
Sensitivity	**1**	**2**	**5**	**0**	**0**	**0**

Metodología de evaluación y validación basada en un esquema de validacion cruzada

Mejoras respecto a A (en duplas)	A	A.1	A.2	A.3	B.1	C.1
Precision	**0**	**3**	**0**	**1**	**3**	**1**
Sensitivity	**0**	**1**	**0**	**0**	**3**	**4**

Experimentos sobre tiempos de cómputo

Se presentan los tiempos de cómputo de

- Estimación de poses
- Reconstrucción de poses faltantes (Variantes A.1 y A.3)
- Heurística de detección de inicio y fin de una caída (Variantes B.1 y C.1)
- Eliminacion de poses posteriores a una caída (Variantes B.1 y C.1)
- Eliminacion de puntos correspondientes a la cabeza (Variantes B.1 y C.1)
- Instanciación de la arquitectura
- Compilación de la arquitectura
- Entrenamiento y validación (MPF y MVC)
- Detección de una caída

Hardware y Sistema Operativo

- Procesador AMD Ryzen 5 2600X
- Acelerador gráfico NVIDIA RTX A4000 limitado al 50%
- RAM de 24GB DDR4
- Almacenamiento de 442GB
- Sistema operativo Debian Linux v13.4

Tiempos de estimación de pose

Esta etapa involucra la medición del tiempo total requerido para que un estimador de pose **E** procese de manera secuencial la totalidad de las imágenes que componen un *dataset* **D**

Proceso de estimación de pose				
Estimador	*Datasets*			
	UP-Fall	Le2i	UR-Fall	GMDCSA24-A
AlphaPose	10808.09	1799.03	987.53	1974.78
MediaPipe	13109.02	1843.1	636.85	991.99
OpenPose	28069.38	3695.41	1376.93	3351.9
YOLOv8-pose	8184.45	489.23	232.88	430.96

Todas las duplas que incluyen al estimador **OpenPose** obtienen los mayores valores de tiempo de cómputo.

Todas las duplas que incluyen al estimador **YOLOv8-pose** obtienen los menores valores de tiempo de cómputo.

Reconstrucción de poses faltantes (Variantes A.1 y A.3)

Medición del tiempo de ejecutar la función matemática ***Cubic Spline interpolation*** para reconstruir las poses no detectadas por el estimador.

Reconstrucción de poses faltantes			
Estimador	*Dataset*		
	UP-Fall	Le2i	UR-Fall
AlphaPose	276.28	11.34	11.62
MediaPipe	491.45	52.95	15.7
OpenPose	319.16	35.18	31.87
YOLOv8-pose	200.77	6.95	7.53

Las diferencias se encuentran condicionadas tanto por el estimador de pose empleado **E** como por el volumen de cada *dataset* **D**.

El *dataset* **UP-Fall** obtiene los mayores tiempos de cómputo para todos los estimadores de pose.

Los estimadores **MediaPipe** y **OpenPose** requieren los mayores tiempos de cómputo para la reconstrucción de poses.

Heurística para la detección del inicio y fin de una caída (Variantes B.1 y C.1)

Esta etapa incluye el tiempo requerido para ejecutar la heurística necesaria para la identificación de la pose de inicio y la pose de fin de cada evento de caída.

Heurística de detección de inicio y fin de caída	
Estimador	*Dataset*
	UP-Fall
AlphaPose	0.27
MediaPipe	0.29
OpenPose	0.27
YOLOv8-pose	0.34

Todos los valores se encuentran en un rango cercano, demostrando que casi no hay variación al aplicar la heurística en distintos estimadores de pose.

Eliminación de puntos y poses (Variantes B.1 y C.1)

Eliminación de puntos correspondientes a la cabeza de una pose		
Dataset	Estimador	B.1, C.1
UP-Fall	AlphaPose	**4.38**
	OpenPose	4.64
	Mediapipe	6.54
	YOLOv8-pose	4.54
Le2i	AlphaPose	0.75
	OpenPose	0.47
	Mediapipe	0.64
	YOLOv8-pose	**0.42**
GMDCSA24-A	AlphaPose	**0.54**
	OpenPose	0.55
	Mediapipe	0.83
	YOLOv8-pose	0.55

Eliminación de poses posteriores a una caída		
Dataset	Estimador	B.1, C.1
UP-Fall	AlphaPose	**0.03**
	OpenPose	**0.03**
	Mediapipe	0.04
	YOLOv8-pose	**0.03**
Le2i	AlphaPose	5.00E-03
	OpenPose	**4.20E-03**
	Mediapipe	4.60E-03
	YOLOv8-pose	5.20E-03
GMDCSA24-A	AlphaPose	**4.10E-03**
	OpenPose	4.20E-03
	Mediapipe	4.40E-03
	YOLOv8-pose	4.30E-03

Tiempo de instanciación de la arquitectura

Medición del tiempo comprendido para construir la estructura base de las arquitecturas y reservar su espacio en memoria.

En el caso del enfoque **A** y sus variantes, esta métrica cuantifica el tiempo de **declaración y encadenamiento** de las capas de convolución y memoria a corto-largo plazo (TD-CNN-LSTM).

Para las variantes **B.1** y **C.1**, esta métrica refleja el tiempo requerido para la **inicialización de los modelos basados en *Transformers*** y su posterior transferencia explícita a la memoria de la GPU

Instanciación de arquitectura							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	0.07	0.07	0.07	0.07	0.00826	**0.00291**
	OpenPose	0.07	0.07	0.07	0.07	0.00989	**0.0029**
	Mediapipe	0.07	0.07	0.07	0.07	0.00832	**0.00293**
	YOLOv8-pose	0.07	0.07	0.07	0.07	0.00883	**0.00289**
Le2i	AlphaPose	0.07	0.07	0.07	0.07	0.00894	**0.00289**
	OpenPose	0.07	0.07	0.07	0.07	0.00879	**0.00289**
	Mediapipe	0.07	0.07	0.07	0.07	0.00855	**0.00293**
	YOLOv8-pose	0.07	0.07	0.07	0.07	0.00807	**0.0029**
UR-Fall	AlphaPose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	OpenPose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	Mediapipe	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	YOLOv8-pose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	0.00839	**0.0029**
	OpenPose	N/A	N/A	N/A	N/A	0.00824	**0.00288**
	Mediapipe	N/A	N/A	N/A	N/A	0.0083	**0.00293**
	YOLOv8-pose	N/A	N/A	N/A	N/A	0.00826	**0.00289**

La variante C.1 requiere un tiempo de instanciación mínimo debido al **diseño optimizado** de su arquitectura.

La variante **B.1** exhibe un incremento temporal debido a su **composición híbrida interna.**

El Enfoque A y sus variantes registran los mayores tiempos debido a la **alta densidad** de su esquema híbrido **TD-CNN-LSTM**.

Tiempo de compilación de la arquitectura

Medición del tiempo asociado a la **preparación de la arquitectura** para la ejecución del entrenamiento.

Para el **enfoque A y sus variantes**, esta etapa representa el tiempo de la generación del **grafo computacional estático**, y la vinculación de la función de pérdida y el optimizador. Se abstrae la arquitectura como un grafo estático donde las operaciones matemáticas actúan como nodos y los flujos de tensores como aristas; esta generación se realiza de forma previa a la introducción de los datos.

Las variantes B.1 y C.1, se basan en **grafos dinámicos** que se declaran y configuran sobre la marcha durante el flujo de ejecución. Se cuantificó el tiempo exacto requerido para la **vinculación** de los **parámetros de la arquitectura** al **optimizador** Adam y la función **WFL**.

Como se puede observar, los tiempos de compilación de la arquitectura **C.1** son los menores valores, luego le sigue **B.1**, y finalmente **A y sus variantes**. Esto se debe a la diferencia del proceso de compilación entre las arquitecturas.

Compilación de arquitectura							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	0.00453	0.00453	0.00543	0.00556	0.000406	**0.000262**
	OpenPose	0.00455	0.00454	0.00549	0.00534	0.000409	**0.000262**
	Mediapipe	0.00455	0.00454	0.00546	0.00542	0.000413	**0.000262**
	YOLOv8-pose	0.00453	0.00453	0.00549	0.00541	0.000408	**0.000263**
Le2i	AlphaPose	0.00452	0.00453	0.00547	0.00545	0.000407	**0.000261**
	OpenPose	0.00453	0.00453	0.0055	0.00548	0.000404	**0.000261**
	Mediapipe	0.00456	0.00455	0.00546	0.00557	0.000407	**0.000261**
	YOLOv8-pose	0.00455	0.00452	0.00547	0.00552	0.000408	**0.000261**
UR-Fall	AlphaPose	**0.00452**	0.00453	0.00544	0.00552	N/A	N/A
	OpenPose	**0.00453**	0.00454	0.00551	0.00544	N/A	N/A
	Mediapipe	**0.00453**	0.00455	0.00543	0.00538	N/A	N/A
	YOLOv8-pose	0.00456	**0.00453**	0.00549	0.00534	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	0.000407	**0.00026**
	OpenPose	N/A	N/A	N/A	N/A	0.000409	**0.000261**
	Mediapipe	N/A	N/A	N/A	N/A	0.000406	**0.000262**
	YOLOv8-pose	N/A	N/A	N/A	N/A	0.000407	**0.000259**

Tiempo de entrenamiento y validación (MPF)

Entrenamiento y validación							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	2921.29	3445.85	2932.9	3473.33	1945.92	**1440.47**
	OpenPose	2932.44	3498.79	2969.1	3488.38	1870.86	**1389.69**
	Mediapipe	4658.44	5331	4642.1	5338.43	2030.55	**1525.85**
	YOLOv8-pose	3148.72	3534.04	3164.83	3550.19	2089.63	**1554.56**
Le2i	AlphaPose	510.25	539.41	514.77	544.47	212.81	**140.9**
	OpenPose	394.87	448.97	391.36	452.7	166.45	**105.19**
	Mediapipe	696.08	725.1	699.37	727.87	195.05	**126.17**
	YOLOv8-pose	459.94	488.78	462.47	492.32	197.83	**127.34**
UR-Fall	AlphaPose	140.41	159.23	**140.26**	161.35	N/A	N/A
	OpenPose	**102.29**	152.2	104.71	151.06	N/A	N/A
	Mediapipe	165.96	189.36	**161.59**	187.83	N/A	N/A
	YOLOv8-pose	**145.26**	160.28	147.95	164.07	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	158.45	**102.83**
	OpenPose	N/A	N/A	N/A	N/A	138.48	**87.98**
	Mediapipe	N/A	N/A	N/A	N/A	158.63	**101.86**
	YOLOv8-pose	N/A	N/A	N/A	N/A	151.33	**99.27**

La diferencia entre los valores obtenidos por las distintas arquitecturas se fundamenta en el **procesamiento de las ventanas de poses** realizado por cada arquitectura. La variante **C.1** procesa las coordenadas de las poses de una ventana en paralelo gracias al mecanismo de atención de su bloque ***Transformer Encoder***. En la variante **B.1**, el tiempo se incrementa de forma moderada debido a que la arquitectura antes de pasar la ventana de poses al bloque ***Transformer Encoder***, debe procesar bloques convolucionales temporales (**TCN**) para extraer características locales y patrones de movimiento de la ventana de poses de entrada. Por último, el **Enfoque A y sus variantes** exhiben los tiempos de entrenamiento más elevados debido a su naturaleza híbrida. Este enfoque debe realizar un doble esfuerzo: primero, utiliza un modelo **CNN** para extraer las características espaciales de las poses y, en segundo lugar, transfiere esas características a capas recurrentes del modelo **LSTM** que procesan la dimensión temporal a través de poses secuenciales. Esta secuencia de tareas y la incapacidad del modelo **LSTM** de paralelizar las operaciones ralentiza significativamente el proceso de entrenamiento y validación.

Tiempo de entrenamiento y validación (MVC)

El tiempo de cómputo total representa la suma del costo temporal de un proceso iterativo de k pasos (en este caso k = 3). En cada uno de estos pasos, la arquitectura es entrenada desde cero.
El valor que se reporta es la suma total y acumulada de los tiempos de entrenamiento, validación y cálculo de métricas de cada uno de los k pasos.

Entrenamiento y validación							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	4373.07	5168.66	4379.56	5200.02	3381.52	**2033.78**
	OpenPose	4447.25	5300.94	4498.65	5266.65	2109.04	**1948.53**
	Mediapipe	7055.67	8132.26	7056.26	8281.5	3514.63	**1813.61**
	YOLOv8-pose	4735.51	5280.09	4731.34	5271.63	3630.63	**2171.27**
Le2i	AlphaPose	773.15	812.14	776.5	816.67	382.34	**266.1**
	OpenPose	596.82	678.94	596.79	684.98	318.13	**223.69**
	Mediapipe	1062.34	1102.03	1065.2	1102.84	349.78	**249.9**
	YOLOv8-pose	689.67	738.34	689.09	741.92	353.51	**248.43**
UR-Fall	AlphaPose	**209.87**	238.37	211.87	240.4	N/A	N/A
	OpenPose	**160.83**	234.45	162.97	233.24	N/A	N/A
	Mediapipe	244.14	283.79	**243.05**	279.99	N/A	N/A
	YOLOv8-pose	217.74	242.21	**216.03**	245.87	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	305.25	**219.83**
	OpenPose	N/A	N/A	N/A	N/A	276.5	**203.21**
	Mediapipe	N/A	N/A	N/A	N/A	305.53	**222.36**
	YOLOv8-pose	N/A	N/A	N/A	N/A	304.68	**220.37**

La diferencia entre los valores obtenidos por las distintas arquitecturas se fundamenta en el **procesamiento de las ventanas de poses** realizado por cada arquitectura.

Tiempo de detección de una caída

El tiempo de detección de una caída comprende los tiempos de las etapas de captura de video, transferencia de imágenes de video, preprocesamiento para la clasificación de una ventana, clasificación de una ventana y alerta de caída.

Sin embargo, hay dos etapas que impactan fuertemente en la efectividad de la detección de una caída, las cuales son descritas a continuación.

Preprocesamiento para la clasificación de una ventana

Comprende el tiempo requerido por el estimador de pose utilizado para procesar las secuencias de imágenes de video recibidas y extraer las poses que conformarán la ventana a clasificar, el tiempo de la política de selección para identificar a la persona protagonista y la posterior normalización de las poses de esta persona. Particularmente, cuando se evalúan las variantes B.1 y C.1, esta etapa también contabiliza el tiempo destinado a la eliminación de los puntos de articulación correspondientes a la cabeza.

Clasificación de una ventana

Refleja el tiempo que demanda una instancia de la arquitectura ya entrenada para procesar la ventana de poses resultante de los pasos anteriores y realizar una clasificación final.

Preprocesamiento para la clasificación de una ventana

Preprocesamiento para clasificación de 1 ventana promedio			
Enfoque/variante	Tamaño de ventana	Estimador	ventana
B.1 y C.1	18	AlphaPose	0.12
		OpenPose	0.29
		Mediapipe	0.15
		YOLOv8-pose	0.08
	25	AlphaPose	0.21
		OpenPose	0.48
		Mediapipe	0.25
		YOLOv8-pose	0.14
	30	AlphaPose	0.22
		OpenPose	0.57
		Mediapipe	0.3
		YOLOv8-pose	0.17
A, A.1, A.2 y A.3	64	AlphaPose	0.66
		OpenPose	1.52
		Mediapipe	0.79
		YOLOv8-pose	0.44

A y sus variantes poseen un tamaño de ventana de 64 poses para todas sus duplas, mientras que las variantes B.1 y C.1 varían sus tamaños de ventana en base a los fps del *dataset* utilizado
(UP-Fall 18 fps, Le2i 25 fps, GMDCSA24-A 30 fps).

En base a los resultados analizados, se puede observar que a medida que aumenta el tamaño de ventana, aumenta el tiempo promedio de preprocesamiento para la clasificación de la misma.

El estimador **YOLOv8-pose** siempre obtiene el menor tiempo promedio de preprocesamiento. El estimador **OpenPose** siempre obtiene el mayor tiempo promedio de preprocesamiento. Este comportamiento es directamente análogo al ocurrido para la estimación de poses, y se puede apreciar ya que l**a estimación de una pose** es la etapa que obtiene los mayores valores de tiempo dentro del preprocesamiento para la clasificación de una ventana.

Clasificación de una ventana

Clasificación de 1 ventana promedio							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	0.08	0.08	0.08	0.08	0.00218	**0.00102**
	OpenPose	0.07	0.08	0.08	0.08	0.00217	**0.00101**
	Mediapipe	0.08	0.08	0.08	0.08	0.00223	**0.00103**
	YOLOv8-pose	0.08	0.08	0.08	0.08	0.00219	**0.00102**
Le2i	AlphaPose	0.07	0.07	0.08	0.08	0.00216	**0.00102**
	OpenPose	0.07	0.07	0.07	0.07	0.00216	**0.00102**
	Mediapipe	0.07	0.07	0.07	0.07	0.00218	**0.00102**
	YOLOv8-pose	0.07	0.07	0.07	0.08	0.00216	**0.00102**
UR-Fall	AlphaPose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	OpenPose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	Mediapipe	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
	YOLOv8-pose	**0.07**	**0.07**	**0.07**	**0.07**	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	0.00217	**0.00102**
	OpenPose	N/A	N/A	N/A	N/A	0.00216	**0.00102**
	Mediapipe	N/A	N/A	N/A	N/A	0.00218	**0.00102**
	YOLOv8-pose	N/A	N/A	N/A	N/A	0.00217	**0.00103**

La diferencia entre los valores obtenidos por las distintas arquitecturas se fundamenta en el **procesamiento de las ventanas de poses** realizado por cada arquitectura.

Detección de una caída

Detección de una caída							
Dataset	Estimador	A	A.1	A.2	A.3	B.1	C.1
UP-Fall	AlphaPose	0.74	0.74	0.74	0.74	**0.13**	**0.13**
	OpenPose	1.6	1.6	1.6	1.6	**0.29**	**0.29**
	Mediapipe	0.86	0.86	0.86	0.86	**0.15**	**0.15**
	YOLOv8-pose	0.52	0.52	0.52	0.52	**0.09**	**0.08**
Le2i	AlphaPose	0.74	0.74	0.74	0.74	**0.21**	**0.21**
	OpenPose	1.6	1.6	1.6	1.6	**0.48**	**0.48**
	Mediapipe	0.86	0.86	0.86	0.86	**0.25**	**0.25**
	YOLOv8-pose	0.52	0.52	0.52	0.52	**0.14**	**0.14**
UR-Fall	AlphaPose	**0.74**	**0.74**	**0.74**	**0.74**	N/A	N/A
	OpenPose	**1.6**	**1.6**	**1.6**	**1.6**	N/A	N/A
	Mediapipe	**0.86**	**0.86**	**0.86**	**0.86**	N/A	N/A
	YOLOv8-pose	**0.52**	**0.52**	**0.52**	**0.52**	N/A	N/A
GMDCSA24-A	AlphaPose	N/A	N/A	N/A	N/A	**0.22**	**0.22**
	OpenPose	N/A	N/A	N/A	N/A	**0.57**	**0.57**
	Mediapipe	N/A	N/A	N/A	N/A	**0.3**	**0.3**
	YOLOv8-pose	N/A	N/A	N/A	N/A	**0.17**	**0.17**

Comprende la suma de la medición de los tiempos de preprocesamiento para la clasificación de una ventana y el tiempo para la clasificación de una ventana.

El enfoque A y sus variantes tienen los mismos valores por dupla en todos los casos.
Asimismo, las variantes B.1 y C.1 tienen los mismos valores por dupla.

Este comportamiento se debe a que los tiempos de la clasificación de una ventana son muy pequeños en comparación a los del preprocesamiento para la clasificación de una ventana. Por esta razón, las variantes que poseen el mismo tiempo de preprocesamiento tienen el mismo tiempo de detección de una caída.

Conclusiones

Luego de analizar los enfoques y variantes en cuanto a métricas y tiempos de cómputo, se puede ver que:

- No hay una combinación de estimador, *dataset* y arquitectura/variante que destaque.
- La etapa de estimación de pose impacta significativamente en el tiempo de detección de una caída.
- En un escenario de detección de una caída, entre las arquitecturas de B.1 y C.1, y entre el enfoque A y sus variantes, no existe una diferencia notoria en los tiempos para la decisión de su implementación.

Este trabajo aporta una referencia para la selección de tecnologías destinadas a la detección automática de caídas en entornos reales. A través de la implementación y evaluación de arquitecturas y variantes frente a datasets y estimadores de pose de referencia en el estado del arte, se ha logrado caracterizar el compromiso existente entre la clasificación de las arquitecturas y el costo temporal de procesamiento, un factor que resulta crítico para la selección de un enfoque visual para la detección automática de caídas bajo restricciones de tiempo real.

Trabajo futuro

- Se plantea la necesidad de evaluar la robustez y capacidad de generalización de las arquitecturas entrenadas mediante su validación frente a *datasets* que presenten características complejas (oclusiones, distintos ángulos de visión, variaciones en la iluminación), como CaucaFall.
- Investigar el impacto de la utilización de *datasets* sintéticos generados artificialmente, tales como el generador OpenSim (Universidad de Stanford), lo que mitigararía la escasez de registros de caídas reales sin vulnerar la privacidad de las personas, sino también enriquecer los conjuntos de entrenamiento con una variedad significativamente mayor de fisonomías humanas, ángulos de cámara y escenarios de simulación.
- Realizar una evaluación de los enfoques y variantes ya entrenados, en un clúster de dispositivos móviles para medir su desempeño en una configuración distribuida.

Universidad Nacional del Centro de la Provincia de Buenos Aires

30 de Junio, 2026

GRACIAS

¿Preguntas?

Alumnos: Gianni Hernán Sottile, Giorgio Iván Loguercio
Directora: Prof. Dr. Virginia Yannibelli